Dispensa di

Social Network Analysis

Corso CT0540

Prof.ssa **Fabiana Zollo**

Dipartimento di Scienze Ambientali, Informatica e Statistica
Università Ca' Foscari di Venezia

Anno Accademico 2025–2026

Questa dispensa sintetizza i materiali didattici del corso CT0540 (Social Network Analysis) tenuto presso l'Università Ca' Foscari di Venezia. I contenuti sono tratti dalle slide, dai notebook e dagli script R utilizzati durante le lezioni. Testi di riferimento principali: Easley & Kleinberg, Networks, Crowds, and Markets (Cambridge, 2012); Barabási, Network Science (Cambridge, 2016).

13 aprile 2026

Indice

1 Introduzione alle Reti Sociali **3**
1.1 Il corso CT0540 . . . 3
1.2 Cosa sono le reti sociali? . . . 3
1.3 Tipi di reti . . . 3
1.4 Testi di riferimento . . . 3
1.5 Ricerca e progetti del gruppo . . . 4

2 Teoria dei Grafi **4**
2.1 Il problema dei ponti di Königsberg . . . 4
2.2 Definizioni fondamentali . . . 4
2.3 Grado e distribuzione di grado . . . 4
2.4 Matrice di adiacenza . . . 5
2.5 Reti sparse . . . 5
2.6 Cammini, distanza e diametro . . . 6
2.7 Il Piccolo Mondo (*Small World*) . . . 6

3 Legami Forti e Deboli **6**
3.1 L'ipotesi di Granovetter . . . 6
3.2 Chiusura Triadica . . . 6
3.3 Coefficiente di Clustering . . . 7
3.4 Ponti e Ponti Locali . . . 7
3.5 La Proprietà di Chiusura Triadica Forte . . . 7

4 Contesti Sociali e Omofilia **7**
4.1 Omofilia . . . 7
4.2 Misurare l'Omofilia . . . 8
4.3 Selezione e Influenza Sociale . . . 8
4.4 Affiliazione e Reti Bipartite . . . 8

5 Analisi delle Reti con R **9**
5.1 Il pacchetto `igraph` . . . 9
5.2 Costruzione di un grafo . . . 9
5.3 Lettura di dati da file . . . 10
5.4 Visualizzazione avanzata . . . 10

6 Misure di Centralità e Citation Networks **11**
6.1 Centralità nelle reti . . . 11
6.2 Centralità di grado (*Degree Centrality*) . . . 11

6.3 Centralità di betweenness 11
6.4 Centralità di vicinanza (*Closeness Centrality*) 11
6.5 Centralità di autovettore (*Eigenvector Centrality*) 12
6.6 Applicazione: Citation Networks con R 12
6.7 Comunità: algoritmo di Girvan–Newman 13

7 Visualizzazione dei Dati 13
7.1 Principi fondamentali 13
7.2 ggplot2 in R 13
7.3 Esempio: Salari dei professori 14
7.4 Buone pratiche 15

8 Filtraggio Dati e Text Analysis 15
8.1 Dataset NYT / COVID-19 15
8.2 Pre-elaborazione del testo con `quanteda` 15
8.3 TF-IDF 16
8.4 Analisi del sentimento 17

9 Topic Modeling con BERTopic 17
9.1 Cos'è il Topic Modeling? 17
9.2 Rappresentazione dei documenti 17
9.3 Il pipeline di BERTopic 18
9.4 Valutazione del modello 19
9.5 Varianti di BERTopic 19

10 Big Data e Dati Sociali 19
10.1 Cosa sono i Big Data? 19
10.2 Sei provocazioni sui Big Data (Boyd & Crawford) 19
10.3 Qualità dei dati sociali 20
10.4 Attributi privati nei dati digitali 21

A Formulario riassuntivo 21

B Glossario 21

Capitolo 1. Introduzione alle Reti Sociali

Il corso CT0540

Il corso **CT0540 – Social Network Analysis** introduce lo studio delle reti complesse con un'enfasi sulle reti sociali. Gli argomenti spaziano dalla teoria matematica dei grafi alle applicazioni pratiche con strumenti come R, fino all'analisi del testo e al topic modeling.

Durata: 30 ore di lezioni frontali. Orari: mercoledì 15:45–17:15 (Lab 5) e venerdì 8:45–10:15.

Cosa sono le reti sociali?

Una **rete sociale** è un insieme di attori (individui, organizzazioni, pagine web, ...) e delle relazioni che li connettono. L'analisi di tali reti consente di studiare:

- come scorrono le informazioni attraverso la società;
- i meccanismi di formazione e dissoluzione dei legami;
- le strutture di potere e influenza;
- fenomeni come la diffusione di notizie false (*misinformation*) o di comportamenti.

Tipi di reti

- **Reti di comunicazione**: nodi = dispositivi/persone, archi = canali di comunicazione (es. ARPANET, Internet).
- **Reti di informazione**: nodi = risorse informative (pagine web, articoli), archi = collegamenti logici (hyperlink, citazioni).
- **Reti sociali**: nodi = persone o gruppi, archi = interazioni sociali (amicizia, collaborazione, follower).
- **Reti biologiche**: reti di interazione tra proteine, reti neurali, ecc.

Testi di riferimento

- D. Easley & J. Kleinberg, *Networks, Crowds, and Markets*, Cambridge University Press, 2012. (Bozza pre-pubblicazione liberamente disponibile online.)
- A.-L. Barabási, *Network Science*, Cambridge University Press, 2016.

Ricerca e progetti del gruppo

La Prof.ssa Zollo guida il *Laboratory of Data Science for Society* di Ca' Foscari e coordina diversi progetti europei legati alle reti sociali digitali: IRIS (ecosistemi informativi sani), EUMEPLAT (identità europea nei media), IMSyPP (hate speech), QUEST (comunicazione scientifica).

Capitolo 2. Teoria dei Grafi

Il problema dei ponti di Königsberg

Nel 1735, Königsberg (Prussia Orientale) era attraversata dal fiume Pregel e disponeva di **sette ponti**. Il quesito classico era: è possibile compiere una passeggiata che attraversi ciascun ponte esattamente una volta?

Soluzione di Eulero (1736). Euler modellò il problema con un grafo: quattro nodi (A, B, C, D) corrispondenti ai lembi di terra e sette archi corrispondenti ai ponti. Dimostrò che un cammino euleriano (che attraversa ogni arco una sola volta) *esiste* se e solo se il grafo ha **al più due nodi di grado dispari**. Nel grafo di Königsberg tutti e quattro i nodi hanno grado dispari $\rightarrow$ nessun cammino ammissibile.

Lezioni chiave:

1. Alcuni problemi diventano più semplici se rappresentati come grafi.
2. I grafi possiedono proprietà intrinseche che limitano o amplificano i comportamenti della rete.

Definizioni fondamentali

Definizione (Grafo). Un grafo $G = (V, E)$ è definito da un insieme di nodi (o vertici) V e un insieme di archi $E \subseteq V \times V$.

Definizione (Grafo non orientato). Gli archi non hanno direzione: $(u, v) \equiv (v, u)$.

Definizione (Grafo orientato (digrafo)). Gli archi hanno una direzione: $(u, v) \neq (v, u)$.

Definizione (Rete pesata). Ogni arco (i, j) ha un peso $w_{ij} \in \mathbb{R}$.

Grado e distribuzione di grado

Il **grado** k_i di un nodo i è il numero di archi che lo collegano ad altri nodi.

Reti non orientate.

$$L = \frac{1}{2}\sum_{i=1}^{N} k_i \qquad \langle k \rangle = \frac{1}{N}\sum_{i=1}^{N} k_i = \frac{2L}{N}$$

Reti orientate. Si distinguono grado entrante k_i^{in} e uscente k_i^{out}:

$$k_i = k_i^{in} + k_i^{out} \qquad \langle k^{in} \rangle = \frac{L}{N} = \langle k^{out} \rangle$$

Distribuzione di grado.

$$p_k = \frac{N_k}{N}$$

dove N_k è il numero di nodi con grado k. Le reti reali spesso mostrano distribuzioni a *power-law* $p_k \sim k^{-\gamma}$ (reti *scale-free*).

Matrice di adiacenza

Per una rete di N nodi, la matrice di adiacenza $A \in \{0,1\}^{N \times N}$ è definita da:

$$A_{ij} = \begin{cases} 1 & \text{se esiste un arco da } j \text{ a } i \\ 0 & \text{altrimenti} \end{cases}$$

Proprietà:

- G non orientato $\Leftrightarrow$ A simmetrica.
- G ha un self-loop $\Leftrightarrow$ $A_{ii} \neq 0$.
- G completo $\Leftrightarrow$ $A_{ij} \neq 0 \ \forall i \neq j$.

Il grado di un nodo si ricava direttamente dalla matrice:

$$k_i = \sum_{j=1}^{N} A_{ji} = \sum_{j=1}^{N} A_{ij} \quad \text{(non orientato)}$$

Reti sparse

Il numero massimo teorico di archi è:

$$|E|_{\max} = \binom{N}{2} = \frac{N(N-1)}{2}$$

Le reti reali sono tipicamente **sparse**: $|E| \ll |E|_{\max}$. Ad esempio, il Karate Club di Zachary: $|V| = 34$, $|E| = 78$, $|E|_{\max} = 561$.

Cammini, distanza e diametro

Definizione (Cammino). Sequenza di archi $(v_0, v_1), (v_1, v_2), \ldots, (v_{k-1}, v_k)$.

Definizione (Distanza geodesica). $d(u, v)$ è la lunghezza del cammino più breve tra u e v.

Definizione (Diametro). Il diametro di una rete è $\max_{u,v} d(u, v)$.

Il Piccolo Mondo (*Small World*)

L'esperimento di Milgram (1967) suggerì che la distanza media tra due individui negli USA fosse circa **sei gradi di separazione**. Le reti reali mostrano:

1. **Diametro piccolo**: la distanza media cresce come $\log N$.
2. **Alto coefficiente di clustering**: i vicini di un nodo tendono ad essere connessi tra loro.

Questo è il modello di Watts–Strogatz (1998).

Capitolo 3. Legami Forti e Deboli

L'ipotesi di Granovetter

Negli anni '60, il sociologo Mark Granovetter condusse interviste con persone che avevano cambiato lavoro. Scoprì che molti avevano appreso dell'opportunità tramite **conoscenti**, non amici intimi.

Granovetter formulò l'ipotesi della **"forza dei legami deboli"**: i legami deboli (con conoscenti distanti) fungono da *ponti* tra porzioni diverse della rete, trasmettendo informazioni nuove non disponibili nel proprio gruppo stretto.

Chiusura Triadica

Definizione (Chiusura triadica). Se A è amico di B e di C, allora esiste una probabilità elevata che B e C diventino amici nel tempo.

Ragioni della chiusura triadica:

1. **Opportunità**: B e C si incontrano attraverso A.
2. **Fiducia**: la conoscenza comune A funge da garante.
3. **Incentivo**: la tensione cognitiva spinge verso equilibrio.

Coefficiente di Clustering

Il **coefficiente di clustering locale** di un nodo i con grado k_i è:

$$C_i = \frac{2L_i}{k_i(k_i - 1)}$$

dove L_i è il numero di archi tra i vicini di i.

$C_i = 0$: nessuno dei vicini è connesso tra loro. $C_i = 1$: tutti i vicini formano un grafo completo.

Il **coefficiente di clustering medio** di una rete è:

$$\langle C \rangle = \frac{1}{N} \sum_{i=1}^{N} C_i$$

Ponti e Ponti Locali

Definizione (Ponte). Un arco (A, B) è un ponte se la sua rimozione disconnette A e B (li porta in componenti distinte).

Definizione (Ponte locale). Un arco (A, B) è un ponte locale se A e B non hanno nessun amico in comune. La sua rimozione aumenta la distanza $d(A, B) > 2$.

Relazione con la chiusura triadica: un arco è un ponte locale precisamente quando non forma il lato di nessun triangolo. Ponti locali e chiusura triadica sono concetti opposti.

La Proprietà di Chiusura Triadica Forte

Categorizzando i legami in **forti** (amici intimi) e **deboli** (conoscenti):

Proprietà STCP. Se un nodo A ha legami forti con B e C, allora esiste un legame (almeno debole) tra B e C.

Conseguenza. I legami deboli sono candidati naturali a essere ponti locali: se A–B fosse forte e fosse un ponte locale, violerebbero STCP. Questo spiega perché i legami deboli portano informazioni nuove.

Capitolo 4. Contesti Sociali e Omofilia

Omofilia

Definizione (Omofilia). Il principio per cui tendiamo ad essere simili ai nostri amici.

I legami nelle reti sociali tendono a connettere persone simili per età, etnia, luogo di residenza, occupazione, interessi e opinioni. L'omofilia può guidare la formazione di legami e rafforzare la chiusura triadica: se A–B e A–C sono amici, l'omofilia suggerisce che B e C siano già simili tra loro, aumentando la probabilità di un legame B–C.

Misurare l'Omofilia

Dato un attributo categorico (es. genere) con frazione p di nodi tipo "maschio" e frazione $q = 1 - p$ di nodi tipo "femmina":

Se i legami fossero formati casualmente, la frazione attesa di archi *eterogenei* (che collegano i due tipi) sarebbe:

$$2pq$$

Se la frazione osservata di archi eterogenei è *minore* di $2pq$, la rete mostra **omofilia**; se è *maggiore*, mostra **eterofilia**.

Selezione e Influenza Sociale

Due meccanismi generano l'omofilia osservata:

- **Selezione**: le persone formano legami con chi è già simile a loro (*"birds of a feather flock together"*).
- **Influenza sociale**: i legami esistenti modificano i comportamenti e le caratteristiche degli individui (*peer pressure*).

Caratteristiche immutabili (sesso biologico, etnia): solo la selezione opera.
Caratteristiche mutabili (comportamenti, opinioni, interessi): entrambi i meccanismi operano.

Esempio. Studi longitudinali sugli adolescenti (Cohen & Kandel) mostrano che sia selezione sia influenza sociale spiegano la somiglianza comportamentale tra amici, con l'influenza sociale più moderata della selezione. Capire quale meccanismo prevalga è fondamentale per progettare interventi efficaci (es. programmi anti-droga).

Affiliazione e Reti Bipartite

Possiamo modellare reti che includono sia **persone** sia **contesti** (focus group, club, classi, eventi) come nodi, connettendo persone ai contesti in cui partecipano. Si ottiene una **rete bipartita**: due tipi di nodi, archi solo tra tipi diversi.

La **proiezione** su un tipo di nodi crea archi tra persone che condividono un contesto, spiegando così l'emergere dell'omofilia anche senza scelta esplicita di amici simili.

Capitolo 5. Analisi delle Reti con R

Il pacchetto `igraph`

La libreria **igraph** (disponibile per R e Python) è lo strumento standard per l'analisi e la visualizzazione di reti. Si installa con:

```
install.packages("igraph")
library(igraph)
```

Costruzione di un grafo

```
# Grafo diretto vuoto
g <- graph.empty(directed = TRUE)

# Aggiunta di nodi
g <- g + vertex("Elizabeth II")
g <- g + vertex("Philip")
g <- g + vertex("Charles")
g <- g + vertex("Diana")
g <- g + vertex("William")

# Aggiunta di archi
g <- g + edges("Elizabeth II", "Charles")
g <- g + edges("Philip",       "Charles")
g <- g + edges("Charles",      "William")
g <- g + edges("Diana",        "William")

plot.igraph(g)
```

```
# Grafo da lista di archi
g1 <- graph(edges = c(1,2, 2,3, 3,1), n = 3, directed =
   FALSE)
plot(g1)

# Grafo con nomi
g3 <- graph(c("John","Jim","Jim","Jill","Jill","John"))
plot(g3)

# Grafo da formula letterale
plot(graph_from_literal(a---b, b---c))  # non orientato
plot(graph_from_literal(a--+b, b+--c)) # orientato
```

Lettura di dati da file

```
# Dataset 1: rete media (orientata, lista di archi)
nodes <- read.csv("Dataset1-Media-Example-NODES.csv",
                  header = TRUE, as.is = TRUE)
links <- read.csv("Dataset1-Media-Example-EDGES.csv",
                  header = TRUE, as.is = TRUE)
net <- graph_from_data_frame(d = links, vertices = nodes,
                             directed = TRUE)
plot(net, edge.arrow.size = 0.4, edge.curved = 0.1)
```

```
# Dataset 2: rete bipartita (matrice di incidenza)
nodes2 <- read.csv("Dataset2-Media-User-Example-NODES.csv
   ",
                   header = TRUE, as.is = TRUE)
links2 <- read.csv("Dataset2-Media-User-Example-EDGES.csv
   ",
                   header = TRUE, row.names = 1)
links2 <- as.matrix(links2)
net2   <- graph_from_incidence_matrix(links2)
table(V(net2)$type)  # numero nodi per tipo
plot(net2, vertex.label = NA)
```

Visualizzazione avanzata

```
# Colori per tipo di medium
colrs <- c("gray50", "tomato", "gold")
V(net)$color <- colrs[V(net)$media.type]

# Dimensione nodi proporzionale al grado
V(net)$size <- degree(net) * 2

# Stile degli archi
E(net)$width  <- E(net)$weight / 5
E(net)$arrow.size <- 0.3

plot(net,
     vertex.label = V(net)$media,
     vertex.label.color = "black",
     vertex.label.cex = 0.7,
     layout = layout_with_fr(net))
```

```r
# Rete bipartita con proiezioni
net2.bp <- bipartite.projection(net2)
plot(net2.bp$proj1,
     vertex.label.color = "black",
     vertex.label.dist  = 1,
     vertex.label = nodes2$media[!is.na(nodes2$media.type)
        ])

# Layout bipartito esplicito
plot(net2, vertex.label = NA, vertex.size = 7,
     layout = layout_as_bipartite)
```

Capitolo 6. Misure di Centralità e Citation Networks

Centralità nelle reti

La **centralità** misura l'importanza di un nodo nella rete. Esistono diverse misure, ognuna con un'interpretazione diversa di "importanza".

Centralità di grado (*Degree Centrality*)

Il nodo più connesso è quello con il grado massimo:

$$C_D(i) = k_i$$

Centralità di betweenness

La **betweenness centrality** misura quante volte un nodo si trova sui cammini più corti tra coppie di nodi:

$$C_B(i) = \sum_{s \neq i \neq t} \frac{\sigma_{st}(i)}{\sigma_{st}}$$

dove σ_{st} è il numero di cammini più corti tra s e t, e $\sigma_{st}(i)$ quanti di essi passano per i.

I nodi con alta betweenness sono **broker** di informazione.

Centralità di vicinanza (*Closeness Centrality*)

$$C_C(i) = \frac{N-1}{\sum_{j \neq i} d(i,j)}$$

Un nodo con alta closeness raggiunge rapidamente tutti gli altri.

Centralità di autovettore (*Eigenvector Centrality*)

La centralità di autovettore assegna importanza a un nodo in base all'importanza dei suoi vicini:

$$C_E(i) = \frac{1}{\lambda} \sum_{j \in \mathcal{N}(i)} C_E(j)$$

In notazione matriciale: $\mathbf{A}\,\mathbf{x} = \lambda\,\mathbf{x}$ dove $\mathbf{x}$ è l'autovettore associato all'autovalore massimo. PageRank di Google è una variante.

Applicazione: Citation Networks con R

```r
library(igraph)

# Caricamento dati
allCounts <- as.matrix(read.csv("ac.csv", as.is = TRUE))
G <- graph.edgelist(allCounts, directed = FALSE)

# Sottografo su specifici temi
themes <- read.csv("themes.csv", as.is = TRUE)
matchingCases     <- which(themes$issue %in% c(20040,
    20050))
matchingCases_ids <- themes$usid[matchingCases]
H <- induced.subgraph(G, matchingCases_ids)

# Layout di Fruchterman-Reingold
set.seed(1)
lout <- layout.fruchterman.reingold(H)
plot.igraph(H, layout = lout, vertex.size = 5,
            vertex.label.cex = 0.5)
```

```r
# Eigenvector Centrality
eigenCent <- evcent(H)$vector
sort(eigenCent, decreasing = TRUE)[1:10]

# Colorazione heat map per centralita'
bins     <- unique(quantile(eigenCent, seq(0, 1, length.
    out = 30)))
vals     <- cut(eigenCent, bins, labels = FALSE, include.
    lowest = TRUE)
colorVals <- rev(heat.colors(length(bins)))[vals]
V(H)$color <- colorVals
plot.igraph(H, vertex.label = NA, vertex.size = 5)
```

```r

# Betweenness Centrality
betweenCent <- betweenness(H)
sort(betweenCent, decreasing = TRUE)[1:10]
cor(betweenCent, eigenCent)   # correlazione tra le due misure
```

Comunità: algoritmo di Girvan–Newman

L'algoritmo di **Girvan–Newman** individua comunità rimuovendo iterativamente gli archi con betweenness più alta (gli archi "ponti" tra comunità).

```r
# Rilevamento comunita' tramite edge betweenness
w <- edge.betweenness.community(H)
sort(table(w$membership))   # distribuzione delle comunita'
```

Capitolo 7. Visualizzazione dei Dati

Principi fondamentali

Una buona visualizzazione deve:

1. Mostrare i dati veritieramente, senza distorsioni.
2. Facilitare il confronto.
3. Essere comprensibile al pubblico di riferimento.
4. Scegliere il tipo di grafico adatto al tipo di dato.

ggplot2 in R

ggplot2 implementa la *Grammar of Graphics*: ogni visualizzazione si compone di dati, mapping estetici (*aesthetics*) e oggetti geometrici (*geom*).

```r
library(ggplot2)

# Scatterplot base
ggplot(data = mpg) +
  geom_point(mapping = aes(x = displ, y = hwy))

# Colore per classe
ggplot(data = mpg) +
```

```
  geom_point(mapping = aes(x = displ, y = hwy, color =
     class))

# Dimensione per classe
ggplot(data = mpg) +
  geom_point(mapping = aes(x = displ, y = hwy, size =
     class))

# Facets (griglia di grafici per sotto-gruppi)
ggplot(data = mpg) +
  geom_point(mapping = aes(x = displ, y = hwy)) +
  facet_wrap(~ class)
```

```
# Curva smoothing
ggplot(data = mpg) +
  geom_smooth(mapping = aes(x = displ, y = hwy))

# Linee differenti per tipo di trazione
ggplot(data = mpg) +
  geom_smooth(mapping = aes(x = displ, y = hwy, linetype =
      drv))

# Combinare piu' geom
ggplot(data = mpg) +
  geom_point(mapping  = aes(x = displ, y = hwy)) +
  geom_smooth(mapping = aes(x = displ, y = hwy))
```

Esempio: Salari dei professori

```
library(car)
data(Salaries)

# Correlazione tra stipendio e anni dal PhD
with(Salaries, cor(salary, yrs.since.phd))   # ~0.42
with(Salaries, cor(salary, yrs.service))     # ~0.33

# Test di correlazione
with(Salaries, cor.test(salary, yrs.since.phd))
```

Buone pratiche

- Evitare grafici a torta per più di 4-5 categorie (preferire barplot).
- Non troncare l'asse Y (a meno che non sia esplicitamente giustificato).
- Usare colori accessibili (palette friendly per daltonici).
- Includere sempre assi etichettati, titolo e fonte dei dati.
- Scegliere la scala appropriata (lineare vs. logaritmica).

Capitolo 8. Filtraggio Dati e Text Analysis

Dataset NYT / COVID-19

L'analisi testuale del corso utilizza un corpus di post Facebook del *New York Times* relativi alla pandemia COVID-19. Il workflow di preprocessing è il seguente.

```
posts <- read.csv("nyt_posts.csv")
posts <- posts[, -(37:40)]     # rimozione colonne inutili
dim(posts)

# Filtraggio per engagement minimo
p <- posts[posts$Likes > 4 & posts$Comments > 4 &
   posts$Shares > 4, ]
paste0(round(dim(p)[1] / dim(posts)[1], 2) * 100, "%")

# Estrazione ID post dall'URL
library(stringr)
p$post_id <- str_sub(p$URL, 43, 60)
table(p$Type)
```

```
# Selezione post con "COVID-19" nel testo
m <- as.character(df_other$text)
y <- which(unlist(lapply(m, function(x) {
       grepl("COVID-19", x, ignore.case = TRUE)
     })))
posts_covid_m <- df_other[y, ]
```

Pre-elaborazione del testo con `quanteda`

```
library(quanteda)
source("stopwords_extended.R")
```

```r

# Costruzione del corpus
corpus <- corpus(posts_covid_lm, text_field = "text")

# Tokenizzazione e pulizia
doc.tokens <- tokens(corpus)
doc.tokens <- tokens(doc.tokens,
                     remove_punct    = TRUE,
                     remove_numbers = TRUE)
doc.tokens <- tokens_select(doc.tokens,
                stopwords(language = "en", source = "
                   snowball"),
                selection = "remove")
doc.tokens <- tokens_select(doc.tokens, stopmore,
                            selection = "remove")
doc.tokens <- tokens_tolower(doc.tokens)
toks_ngram  <- tokens_ngrams(doc.tokens, n = 1:2)

# Document-Feature Matrix (DFM)
dfmat1 <- dfm(toks_ngram) |> dfm_trim(min_termfreq = 10)
dfmat1
```

TF-IDF

Il peso **TF-IDF** (*Term Frequency – Inverse Document Frequency*) misura l'importanza di un termine t in un documento d rispetto a un corpus D:

$$\mathrm{TF}(t,d) = \frac{f_{t,d}}{\sum_{t'} f_{t',d}} \qquad \mathrm{IDF}(t,D) = \log \frac{|D|}{|\{d \in D : t \in d\}|}$$

$$\text{TF-IDF}(t,d,D) = \mathrm{TF}(t,d) \times \mathrm{IDF}(t,D)$$

Termini molto frequenti in tutto il corpus (es. "the", "a") ricevono IDF basso e quindi peso basso, mentre termini specifici di pochi documenti ricevono peso alto.

```r
library(quanteda.textstats)

# 100 termini piu' frequenti
features_dfm <- textstat_frequency(dfmat1, n = 100)

# TF-IDF
dfmat_tfidf <- dfm_tfidf(dfmat1)
```

Analisi del sentimento

L'analisi del sentimento assegna a testi un punteggio di valenza emotiva (positivo, negativo, neutro). Approcci principali:

- **Dizionari lessicali** (es. AFINN, BING, NRC): lookup diretto.
- **Modelli ML supervisionati**: classificatori addestrati su testi annotati.
- **Modelli basati su trasformatori** (BERT): catturano il contesto.

Capitolo 9. Topic Modeling con BERTopic

Cos'è il Topic Modeling?

Il **topic modeling** è una tecnica di apprendimento non supervisionato per scoprire temi latenti in un corpus di testi. Dato un insieme di documenti (tweet, articoli, commenti, ecc.), l'obiettivo è assegnare automaticamente ogni documento a uno o più argomenti.

Rappresentazione dei documenti

Bag of Words (BoW). Ogni documento è rappresentato dalla frequenza delle sue parole (vettore sparso).

✓ Semplice, interpretabile.

× Perde informazione sintattica e semantica; problemi con omonimia ed enantiosemia.

Embeddings (word2vec, BERT). Ogni parola/frase viene mappata in un vettore denso nello spazio $\mathbb{R}^d$ dove la similarità vettoriale riflette la similarità semantica.

Il modello **BERT** (*Bidirectional Encoder Representations from Transformers*) legge il testo in entrambe le direzioni e produce rappresentazioni contestuali. **Sentence-BERT** (SBERT) usa il *mean pooling* sulle rappresentazioni per ottenere un embedding a livello di frase.

✓ Nessun preprocessing testuale specifico; mantiene il contesto.

× Non interpretabile; limite di lunghezza (500 token $\approx$ 300 parole).

Il pipeline di BERTopic

BERTopic (Grootendorst, 2022) combina quattro passi:

1. **Embedding dei documenti** tramite SBERT: ogni documento diventa un vettore in uno spazio ad alta dimensione ($d \approx 768$).
2. **Riduzione della dimensionalità** con UMAP: da $\mathbb{R}^{768}$ a $\mathbb{R}^5$ (o meno), preservando la struttura locale.
3. **Clustering** con HDBSCAN: raggruppa documenti semanticamente simili in cluster; i documenti fuori da tutti i cluster sono etichettati come "rumore".
4. **Rappresentazione dei topic** con c-TF-IDF: per ogni cluster si calcola un TF-IDF "classico" applicato ai cluster come fossero documenti.

UMAP (Uniform Manifold Approximation and Projection). UMAP riduce la dimensionalità preservando la struttura locale dei dati:

1. Costruisce un grafo di vicinanza nello spazio ad alta dimensione.
2. Costruisce un grafo equivalente in bassa dimensione.
3. Minimizza la *cross-entropy loss* tra i due grafi tramite discesa del gradiente stocastica.

Il risultato è una proiezione che preserva i cluster semantici. La qualità dipende dal parametro K (numero di vicini considerati).

HDBSCAN (Hierarchical DBSCAN). HDBSCAN è un algoritmo di clustering basato sulla densità che:

- non richiede di specificare il numero di cluster *a priori*;
- individua cluster di forma arbitraria;
- etichetta come rumore i punti in regioni a bassa densità.

c-TF-IDF (class-TF-IDF). Per ottenere le parole rappresentative di ogni topic, BERTopic unisce tutti i documenti di un cluster in un unico "meta-documento" e calcola:

$$c\text{-TF-IDF}_{t,c} = \frac{f_{t,c}}{\sum_{t'} f_{t',c}} \times \log\left(1 + \frac{A}{f_t}\right)$$

dove $f_{t,c}$ è la frequenza di t nel cluster c, f_t è la frequenza totale di t nel corpus, e A è il numero medio di parole per classe.

Valutazione del modello

Metriche comuni:

- **Coherence score**: misura la coerenza semantica dei topic.
- **Diversity score**: misura quanto i topic siano distinti tra loro.
- **Ispezione manuale**: lettura delle parole chiave e dei documenti rappresentativi di ciascun topic.

Varianti di BERTopic

- **Dynamic Topic Modeling**: evoluzione dei topic nel tempo.
- **Guided Topic Modeling**: incorporazione di seed words.
- **Zero-shot Topic Modeling**: classificazione senza dati di addestramento.
- **Online Topic Modeling**: aggiornamento incrementale del modello.

Capitolo 10. Big Data e Dati Sociali

Cosa sono i Big Data?

"*Big Data*" è un termine spesso frainteso: non si riferisce semplicemente a grandi quantità di dati, ma a una **capacità di ricerca, aggregazione e incrocio** di insiemi di dati eterogenei [**?**, Boyd & Crawford, 2012].

Due interpretazioni prevalenti:

1. **Strumento potente**: permette di affrontare questioni sociali complesse su larga scala.
2. **Manifestazione preoccupante**: rischi per la privacy, la libertà civile e il controllo governativo/corporativo.

Le quattro forze regolatrici dei sistemi sociali (Lessig, 1999): *mercato*, *legge*, *norme sociali*, *architettura (codice)*. Queste forze sono spesso in conflitto nell'ecosistema dei Big Data.

Sei provocazioni sui Big Data (Boyd & Crawford)

1. I Big Data cambiano la definizione di conoscenza. L'emergere di sistemi computazionali per l'analisi dei dati modifica il modo in cui costruiamo conoscenza scientifica e sociale. I tool disponibili hanno limitazioni strutturali (es. archivi Twitter/Facebook di difficile accesso) che condizionano le domande di ricerca.

2. I claim di obiettività e accuratezza sono fuorvianti. Tutti i ricercatori interpretano i dati. Le scelte di design (cosa misurare, come pulire i dati, quali variabili includere) sono soggettive. I grandi dataset possono contenere errori sistematici che si amplificano con la combinazione di fonti diverse.

3. I Big Data non sono equivalenti ai Big Data. L'accesso ai dati non è democratico: grandi aziende e governi hanno accesso privilegiato che i ricercatori accademici non hanno. I dati disponibili dipendono da scelte commerciali e politiche, non dalla rilevanza scientifica.

4. Molte forme di analisi dei Big Data producono correlazioni, non causalità. La correlazione statistica tra variabili non implica un nesso causale. I Big Data facilitano la scoperta di pattern ma non necessariamente la loro spiegazione causale. Occorre rigore metodologico per non trarre conclusioni errate.

5. Le questioni etiche sono complesse.

- **Consenso informato**: i dati social sono pubblici, ma non necessariamente ceduti per scopi di ricerca.
- **Anonimizzazione**: dati apparentemente anonimi possono essere re-identificati.
- **Discriminazione algoritmica**: modelli addestrati su dati storici possono perpetuare discriminazioni.

6. Accesso asimmetrico ai Big Data crea nuove disparità. La divisione tra chi ha e chi non ha accesso ai grandi dataset crea disuguaglianze nella produzione di conoscenza e nel potere decisionale.

Qualità dei dati sociali

- **Completezza**: i dati social coprono solo una porzione della popolazione (sesgo di selezione).
- **Accuracy**: errori di misurazione, bot, account falsi.
- **Consistenza**: le piattaforme cambiano le API nel tempo, rendendo difficile la comparazione longitudinale.
- **Temporalità**: le conversazioni online hanno una vita breve; rilevanza del momento di raccolta.

Attributi privati nei dati digitali

La ricerca di Kosinski et al. (2013) dimostrò che i *Facebook likes* permettono di prevedere con alta accuratezza attributi privati degli utenti (orientamento sessuale, etnia, opinioni politiche, tratti della personalità). Questo solleva questioni etiche fondamentali sull'uso dei dati digitali.

Capitolo A. Formulario riassuntivo

Misura	Formula	Interpretazione
Grado (non or.)	$k_i = \sum_j A_{ji}$	Numero di vicini
Grado medio	$\langle k \rangle = 2L/N$	Connettività media
Clustering loc.	$C_i = \frac{2L_i}{k_i(k_i-1)}$	Densità locale
Clustering medio	$\langle C \rangle = \frac{1}{N} \sum C_i$	Clustering globale
Betweenness	$C_B(i) = \sum_{s \neq i \neq t} \frac{\sigma_{st}(i)}{\sigma_{st}}$	Ruolo di intermediario
Closeness	$C_C(i) = \frac{N-1}{\sum_{j \neq i} d(i,j)}$	Efficienza di raggiungimento
Eigenvector	$\mathbf{Ax} = \lambda \mathbf{x}$	Importanza dei vicini
TF-IDF	$\text{TF} \times \log(\lvert D \rvert / \text{df})$	Rilevanza termine in doc

Capitolo B. Glossario

Arco (edge) Connessione tra due nodi in un grafo.

Betweenness centrality Misura di centralità basata su cammini più corti.

BERTopic Framework di topic modeling basato su BERT, UMAP e HDBSCAN.

BoW Bag of Words: rappresentazione vettoriale sparsa dei documenti.

Chiusura triadica Tendenza a formare triangoli in reti sociali.

Clustering coefficient Misura della densità di connessioni tra vicini.

Componente connessa Sottografo massimale in cui ogni coppia di nodi è raggiungibile.

Diametro Massima distanza geodesica in un grafo.

Grado (degree) Numero di archi incidenti su un nodo.

Grafo Struttura matematica composta da nodi e archi.

HDBSCAN Hierarchical Density-Based Spatial Clustering.

Homophily Tendenza a legarsi con chi è simile a noi.

igraph Libreria R/Python per analisi di reti.

Matrice di adiacenza Rappresentazione matriciale di un grafo.

Nodo (vertex) Elemento base di un grafo.

Omofilia Vedi Homophily.

Ponte locale Arco che collega nodi senza amici in comune.

Scale-free Rete con distribuzione di grado a power-law.

Sentiment analysis Analisi automatica della valenza emotiva dei testi.

Small world Rete con diametro piccolo e alto clustering.

TF-IDF Term Frequency–Inverse Document Frequency.

Topic modeling Scoperta automatica di temi latenti nei testi.

UMAP Uniform Manifold Approximation and Projection.