Dispensa di

Social Network Analysis

Corso CT0540

Prof.ssa **Fabiana Zollo**

Dipartimento di Scienze Ambientali, Informatica e Statistica
Università Ca' Foscari di Venezia

Anno Accademico 2025–2026

Questa dispensa sintetizza i materiali didattici del corso CT0540 (Social Network Analysis) tenuto presso l'Università Ca' Foscari di Venezia. I contenuti sono tratti dalle slide, dai notebook e dagli script R utilizzati durante le lezioni. Testi di riferimento principali: Easley & Kleinberg, Networks, Crowds, and Markets (Cambridge, 2012); Barabási, Network Science (Cambridge, 2016).

16 aprile 2026

Indice

Capitolo 1. Introduzione alle Reti Sociali

Il corso CT0540

Il corso **CT0540 – Social Network Analysis** introduce lo studio delle reti complesse con un'enfasi sulle reti sociali. Gli argomenti spaziano dalla teoria matematica dei grafi alle applicazioni pratiche con strumenti come R, fino all'analisi del testo e al topic modeling.

Durata: 30 ore di lezioni frontali. Orari: mercoledì 15:45–17:15 (Lab 5) e venerdì 8:45–10:15.

Sistemi complessi e reti

Prima di definire formalmente le reti sociali, è utile collocarle in un contesto più ampio: quello dei **sistemi complessi**. Un sistema complesso è un sistema composto da molte parti interconnesse, la cui disposizione delle connessioni è complicata, e che presenta *proprietà emergenti*: caratteristiche del sistema nel suo insieme che non si possono inferire semplicemente sommando le proprietà dei singoli componenti.

La celebre citazione di Aristotele riassume l'idea: *"Il tutto è più della somma delle sue parti."* In pratica, due neuroni separati non "pensano"; migliardi di neuroni connessi in modo specifico producono la coscienza. Allo stesso modo, due persone isolate non formano una "società"; milioni di relazioni intrecciate generano fenomeni come le mode, le crisi finanziarie, le epidemie.

Esempi di sistemi complessi con struttura a rete:

- **Cervello umano**: circa 9×10^{10} neuroni connessi da sinapsi; la struttura di queste connessioni determina funzioni cognitive e comportamenti.
- **Reti genetiche**: geni e proteine si regolano a vicenda; capire queste interazioni è la chiave per la medicina personalizzata.
- **Internet**: milioni di router e computer connessi; un guasto localizzato può propagarsi a cascata.
- **Economia globale**: imprese, banche e mercati formano una rete finanziaria; il fallimento di una banca può innescare una crisi mondiale.
- **Reti sociali**: persone e organizzazioni connesse da relazioni; un'idea o una malattia si diffondono seguendo questi legami.

La Network Science. La **Network Science** (scienza delle reti) è la disciplina accademica che studia le reti complesse. È *interdisciplinare* per natura: combina la teoria dei grafi dalla matematica, la meccanica statistica dalla fisica, il data mining

e la visualizzazione dall'informatica, la modellazione statistica e la struttura sociale dalla sociologia. Una scoperta fondamentale è che reti di domini completamente diversi (biologia, tecnologia, società) mostrano proprietà strutturali simili, perché sono governate dagli stessi principi organizzativi (Barabási, 2016).

Cosa sono le reti sociali?

Una **rete sociale** è un insieme di attori (individui, organizzazioni, pagine web, ...) e delle relazioni che li connettono. In termini matematici, come vedremo in dettaglio nel prossimo capitolo, si tratta di un *grafo*: i nodi rappresentano gli attori e gli archi rappresentano le relazioni. L'analisi di tali reti consente di studiare:

- come scorrono le informazioni attraverso la società;
- i meccanismi di formazione e dissoluzione dei legami;
- le strutture di potere e influenza;
- fenomeni come la diffusione di notizie false (*misinformation*) o di comportamenti.

Tipi di reti

- **Reti di comunicazione**: nodi = dispositivi/persone, archi = canali di comunicazione (es. ARPANET, Internet).
- **Reti di informazione**: nodi = risorse informative (pagine web, articoli), archi = collegamenti logici (hyperlink, citazioni).
- **Reti sociali**: nodi = persone o gruppi, archi = interazioni sociali (amicizia, collaborazione, follower).
- **Reti biologiche**: reti di interazione tra proteine, reti neurali, ecc.

Testi di riferimento

- D. Easley & J. Kleinberg, *Networks, Crowds, and Markets*, Cambridge University Press, 2012. (Bozza pre-pubblicazione liberamente disponibile online.)
- A.-L. Barabási, *Network Science*, Cambridge University Press, 2016.

I sociogrammi di Moreno: il primo esempio di SNA

Il primo esempio riconosciuto di **Social Network Analysis** risale al 1934, con il lavoro del sociologo Jacob Levy Moreno. Moreno mappò le *affinità sociali* di gruppi di individui — in particolare i bambini di una classe scolastica — chiedendo a ciascuno con chi avrebbe preferito stare seduto. I risultati, che lui chiamò **sociogrammi**, visualizzavano le relazioni di preferenza come frecce tra i nodi.

Dai sociogrammi emergevano fenomeni interessanti: la proporzione di legami tra bambini di sesso diverso diminuiva nel tempo; si formavano strutture comunitarie che poi si dissolvevano; alcuni bambini erano molto popolari (ricevevano molte frecce) mentre altri erano isolati. Questo lavoro pionieristico mostra come una semplice rete possa rivelare la struttura sociale sottostante di un gruppo.

Il Club di Karate di Zachary

Un esempio classico e molto citato nella letteratura sulle reti sociali è il **Club di Karate di Zachary** (Zachary, 1977). Il sociologo Wayne Zachary osservò per due anni i 34 membri di un club universitario di karate. Durante lo studio si sviluppò un conflitto tra il presidente del club (nodo 34) e l'istruttore (nodo 1), che portò alla rottura del gruppo: l'istruttore lasciò e fondò un nuovo club, portando con sé circa metà dei membri.

Zachary costruì una rete delle amicizie tra i membri (usando diverse misure per stimare la forza dei legami) e scoprì una proprietà straordinaria: **l'istruttore e il presidente non erano amici**, e la maggior parte dei membri era amica dell'uno o dell'altro ma non di entrambi. Il metodo di Girvan e Newman (2002), applicato retrospettivamente a questa rete, riuscì a predire quasi perfettamente la divisione del club (solo un membro fu classificato erroneamente), dimostrando che la struttura della rete di amicizie era già un indicatore della divisione che si sarebbe verificata.

Dimensioni della rete: $|V| = 34$ nodi, $|E| = 78$ archi.

Computational Social Science

La sociologia ha sviluppato intuizioni fondamentali sulla struttura delle reti sociali, ma la sua metodologia era necessariamente vincolata alle scale in cui la raccolta dati era possibile: esperimenti di laboratorio, focus group, sondaggi su campioni limitati.

La **Computational Social Science** (Lazer et al., 2009, *Science*) è una disciplina emergente che sfrutta la disponibilità di dati digitali su larga scala per formulare e validare teorie sulle reti sociali. I dati di comunicazione digitale (e-mail, social media, telefonate) permettono di osservare reti di milioni di individui nel tempo, rendendo possibili studi impensabili con i metodi tradizionali.

Il numero di Dunbar

Quanto è grande una tipica rete sociale? Il primatologo e antropologo Robin Dunbar, studiando le reti sociali dei primati, ipotizzò l'esistenza di limiti cognitivi alla dimensione della propria rete sociale: la capacità di elaborazione della neocorteccia pone un limite al numero di individui con cui si può mantenere una relazione stabile. Dunbar stimò che **il numero tipico di relazioni stabili per un essere umano sia circa 150** (*Dunbar's number*).

Questa ipotesi è stata validata su dati reali: uno studio sullo scambio di biglietti di auguri natalizi trovò che la rete media era di 153,5 contatti. Gonçalves, Perra e Vespignani (2011) la validarono su Twitter, analizzando 1,7 milioni di utenti su un periodo di sei mesi: gli utenti mantenevano un numero massimo di **100–200 relazioni stabili**, confermando i limiti cognitivi previsti da Dunbar anche nel mondo online.

Reti di informazione online

Le reti di informazione (pagine web, blog, articoli) hanno una struttura fondamentalmente reticolare. Lo studio dei link tra queste risorse consente di capire come sono raggruppate le comunità di contenuti e quali risorse sono le più autorevoli.

Un esempio emblematico è lo studio di Adamic e Glance (2005), che misurò il grado di interazione tra blog politici liberali e conservativi prima delle elezioni presidenziali USA del 2004. Analizzando 1.494 blog, trovarono che la rete mostrava due cluster ben separati, con i blog conservativi che si citavano tra loro in modo più fitto rispetto ai liberali. Questo rivela come la struttura di rete possa rivelare la *polarizzazione* del discorso politico.

Sulla stessa linea, uno studio di Del Vicario, Zollo et al. (2017) analizzò il dibattito sulla Brexit su Facebook, costruendo una rete di oltre un milione di utenti collegati in base alle interazioni con i contenuti delle principali testate giornalistiche britanniche. La struttura a rete rivelò la polarizzazione dell'opinione pubblica prima del referendum.

Ricerca e progetti del gruppo

La Prof.ssa Zollo guida il *Laboratory of Data Science for Society* di Ca' Foscari e coordina diversi progetti europei legati alle reti sociali digitali: IRIS (ecosistemi informativi sani), EUMEPLAT (identità europea nei media), IMSyPP (hate speech), QUEST (comunicazione scientifica).

Capitolo 2. Teoria dei Grafi

Il problema dei ponti di Königsberg

Nel 1735, Königsberg (Prussia Orientale) era attraversata dal fiume Pregel e disponeva di **sette ponti**. Il quesito classico era: è possibile compiere una passeggiata che attraversi ciascun ponte esattamente una volta?

Soluzione di Eulero (1736). Euler modellò il problema con un grafo: quattro nodi (A, B, C, D) corrispondenti ai lembi di terra e sette archi corrispondenti ai ponti. Dimostrò che un cammino euleriano (che attraversa ogni arco una sola volta) *esiste* se e solo se il grafo ha **al più due nodi di grado dispari**. Nel grafo di Königsberg tutti e quattro i nodi hanno grado dispari $\rightarrow$ nessun cammino ammissibile.

L'ottavo ponte (1875). Nel 1875 gli abitanti di Königsberg costruirono un nuovo ponte tra i nodi B e C. Questo ridusse a uno solo il numero di nodi con grado dispari, rendendo possibile trovare il cammino euleriano. L'esempio illustra concretamente come una piccola modifica alla struttura di un grafo possa cambiarne radicalmente le proprietà.

Lezioni chiave:

1. Alcuni problemi diventano più semplici se rappresentati come grafi.
2. I grafi possiedono proprietà intrinseche che limitano o amplificano i comportamenti della rete.

Definizioni fondamentali

La teoria dei grafi fornisce il linguaggio matematico con cui descrivere qualsiasi struttura reticolare: una mappa della metropolitana, le amicizie su Facebook, le interazioni tra proteine. Prima di procedere con l'analisi, è fondamentale padroneggiare le definizioni di base, perché ogni misura che utilizzeremo — centralità, clustering, distanza — è costruita su questi concetti. Immaginate la rete di conoscenze di una persona: ogni individuo è un *nodo*, ogni rapporto di amicizia o conoscenza è un *arco*. Su questa struttura si fondano tutte le analisi successive.

Definizione (Grafo). Un grafo $G = (V, E)$ è definito da un insieme di nodi (o vertici) V e un insieme di archi $E \subseteq V \times V$.

Definizione (Grafo non orientato). Gli archi non hanno direzione: $(u, v) \equiv (v, u)$.

Definizione (Grafo orientato (digrafo)). Gli archi hanno una direzione: $(u, v) \neq (v, u)$.

Definizione (Rete pesata). Ogni arco (i, j) ha un peso $w_{ij} \in \mathbb{R}$.

Grado e distribuzione di grado

Il **grado** k_i di un nodo i è il numero di archi che lo collegano ad altri nodi.

Reti non orientate.

$$L = \frac{1}{2}\sum_{i=1}^{N} k_i \qquad \langle k \rangle = \frac{1}{N}\sum_{i=1}^{N} k_i = \frac{2L}{N}$$

Reti orientate. Si distinguono grado entrante k_i^{in} e uscente k_i^{out}:

$$k_i = k_i^{in} + k_i^{out} \qquad \langle k^{in} \rangle = \frac{L}{N} = \langle k^{out} \rangle$$

Distribuzione di grado.

$$p_k = \frac{N_k}{N}$$

dove N_k è il numero di nodi con grado k. Le reti reali spesso mostrano distribuzioni a *power-law* $p_k \sim k^{-\gamma}$ (reti *scale-free*).

Spiegazione delle formule. La formula $L = \frac{1}{2}\sum_i k_i$ mostra che il numero totale di archi L si ottiene sommando tutti i gradi dei nodi e dividendo per 2, perché ogni arco è contato due volte: una volta per ciascuno dei suoi due endpoint. Ad esempio, in una rete con tre persone che si conoscono tutte, ogni persona ha grado $k_i = 2$; la somma dei gradi è 6, divisa per 2 dà $L = 3$ archi. Il **grado medio** $\langle k \rangle = 2L/N$ rappresenta il numero medio di vicini per nodo: in una rete Internet dove ogni router ha in media 3 connessioni, $\langle k \rangle = 3$.

Nella versione orientata (digrafo), si distingue tra archi in entrata (*in-degree* k_i^{in}, ad esempio i follower su Twitter) e archi in uscita (*out-degree* k_i^{out}, ad esempio i following). La formula $\langle k^{in} \rangle = L/N = \langle k^{out} \rangle$ dice che in media ogni nodo ha lo stesso numero di follower e following, il che ha senso perché ogni arco orientato aggiunge 1 al grado entrante di un nodo e 1 al grado uscente di un altro.

La **distribuzione di grado** p_k indica la probabilità che un nodo scelto casualmente abbia grado k. In una rete di amici, la maggior parte delle persone ha pochi amici e alcune persone ne hanno molti: questa asimmetria si chiama *power-law* o distribuzione a legge di potenza. Il parametro γ (tipicamente $2 < \gamma < 3$ nelle reti sociali reali) controlla quanto rapidamente le probabilità decrescono all'aumentare del grado: più è piccolo, più frequenti sono i nodi con grado elevatissimo (*hub*).

Matrice di adiacenza

Per una rete di N nodi, la matrice di adiacenza $A \in \{0,1\}^{N \times N}$ è definita da:

$$A_{ij} = \begin{cases} 1 & \text{se esiste un arco da } j \text{ a } i \\ 0 & \text{altrimenti} \end{cases}$$

Proprietà:

- G non orientato $\Leftrightarrow$ A simmetrica.
- G ha un self-loop $\Leftrightarrow$ $A_{ii} \neq 0$.
- G completo $\Leftrightarrow$ $A_{ij} \neq 0 \ \forall i \neq j$.

Il grado di un nodo si ricava direttamente dalla matrice:

$$k_i = \sum_{j=1}^{N} A_{ji} = \sum_{j=1}^{N} A_{ij} \quad \text{(non orientato)}$$

Perché la matrice di adiacenza è utile. La matrice di adiacenza A è la rappresentazione "completa" di un grafo: contiene tutta l'informazione sulla struttura della rete in una forma su cui è possibile eseguire operazioni algebriche. In particolare, il prodotto A^2 ha l'elemento (i, j) pari al numero di cammini di lunghezza 2 da i a j (cioè quanti amici in comune hanno i e j); più in generale, $(A^k)_{ij}$ conta i cammini di lunghezza k. Questo legame tra algebra lineare e proprietà strutturali del grafo è alla base di tecniche come la centralità di autovettore e il PageRank.

Per grafi **non orientati**, A è simmetrica ($A = A^T$), il che implica che gli autovalori di A sono tutti reali — una proprietà fondamentale per l'analisi spettrale delle reti. Per grafi **orientati**, A è in generale asimmetrica: $A_{ij} = 1$ indica un arco da j a i, ma non necessariamente da i a j. La traccia di A (somma degli elementi diagonali) conta i *self-loop*: archi che collegano un nodo a sé stesso, rari nelle reti sociali ma presenti in alcune reti biologiche.

Reti sparse

Il numero massimo teorico di archi è:

$$|E|_{\max} = \binom{N}{2} = \frac{N(N-1)}{2}$$

Le reti reali sono tipicamente **sparse**: $|E| \ll |E|_{\max}$. Ad esempio, il Karate Club di Zachary: $|V| = 34$, $|E| = 78$, $|E|_{\max} = 561$.

Perché la sparsità è importante. In una rete con N nodi, memorizzare la matrice di adiacenza completa richiederebbe $O(N^2)$ di memoria. Per una rete con un milione di nodi, questo significa 10^{12} elementi — circa 1000 GB per valori booleani. Fortunatamente, le reti reali sono sparse: il numero di archi $|E|$ cresce tipicamente in modo lineare con N ($|E| \approx cN$ per qualche costante c), non quadratico. Questo rende praticabile la memorizzazione tramite **liste di adiacenza** (costo $O(N + |E|)$) e il calcolo di proprietà come cammini più corti con algoritmi come BFS/Dijkstra in tempo $O(N + |E|)$.

La sparsità ha anche implicazioni concettuali: in una rete sociale sparsa, ogni individuo conosce una piccola frazione della popolazione totale, eppure grazie alla struttura della rete può raggiungere quasi chiunque in pochi passi — il famoso "piccolo mondo".

Connettività e componenti connesse

Definizione (Componente connessa). Sottoinsieme massimale di nodi tale che (1) ogni coppia di nodi al suo interno è collegata da almeno un cammino, e (2) non esiste un sottoinsieme più grande con la stessa proprietà.

Un grafo con una sola componente connessa si dice **grafo connesso**; in un grafo disconnesso la matrice di adiacenza può essere riscritta in forma a blocchi diagonali.

Grafi orientati. Per i grafi orientati si distingue tra:

- **Componente fortemente connessa**: ogni nodo raggiunge tutti gli altri *seguendo la direzione degli archi.*
- **Componente debolmente connessa**: ogni coppia di nodi è collegata ignorando la direzione degli archi.

Componente gigante (*Giant Component*)

Nelle reti reali di grandi dimensioni il grafo non è quasi mai completamente connesso, ma esiste tipicamente una sola **componente gigante**: una componente connessa che contiene una frazione significativa di tutti i nodi della rete.

Perché di solito ne esiste solo una? Se esistessero due componenti giganti, sarebbe sufficiente un singolo arco per fonderle in una componente ancora più grande. In reti sociali reali tale arco si forma quasi certamente, quindi le due componenti collassano in una.

Rilevanza pratica. La presenza di una grande componente è cruciale per la diffusione di fenomeni (malattie, informazioni, comportamenti): un individuo con un solo contatto diretto può tuttavia fare parte di una componente che raggiunte la maggioranza della popolazione, percorrendo cammini di trasmissione indiretti.

Esempio di emergenza della componente gigante. Immaginate di aggiungere archi uno per uno a un grafo con N nodi isolati (modello di Erdős–Rényi). Per densità molto bassa, la rete consiste in molte piccole componenti isolate. Quando il grado medio $\langle k \rangle$ supera la soglia critica di $\langle k \rangle = 1$, avviene una *transizione di fase*: emerge improvvisamente una componente gigante che ingloba una frazione finita dei nodi. Questo comportamento è analogo alle transizioni di fase in fisica (ad es. il passaggio dell'acqua dallo stato liquido al vapore) e ha importanti implicazioni pratiche: nelle campagne vaccinali, immunizzare un numero sufficiente di individui può "distruggere" la componente gigante e fermare la diffusione di un'epidemia.

Lista di adiacenza. Per memorizzare reti di grandi dimensioni (sparse) è conveniente usare una **lista di adiacenza** anziché la matrice di adiacenza completa: si memorizzano solo gli archi esistenti, riducendo il costo di memoria da $O(N^2)$ a $O(N + L)$.

Cammini, distanza e diametro

Definizione (Cammino). Sequenza di archi $(v_0, v_1), (v_1, v_2), \ldots, (v_{k-1}, v_k)$.

Definizione (Distanza geodesica). $d(u, v)$ è la lunghezza del cammino più breve tra u e v.

Definizione (Diametro). Il diametro di una rete è $d_{\max} = \max_{u,v} d(u, v)$, ovvero la massima distanza geodesica registrata tra qualsiasi coppia di nodi.

Definizione (Lunghezza media del percorso). $\langle d \rangle = \frac{1}{N(N-1)} \sum_{i \neq j} d(i, j)$ è la distanza media tra tutte le coppie di nodi (calcolata solo all'interno della stessa componente connessa).

Il Piccolo Mondo (*Small World*)

L'esperimento di Milgram (1967) suggerì che la distanza media tra due individui negli USA fosse circa **sei gradi di separazione**. Un'analisi successiva su Microsoft Messenger (circa 240 milioni di utenti) stimò una lunghezza media del percorso $\langle d \rangle \approx 6.6$ e una mediana di 7. Le reti reali mostrano tipicamente:

1. $\langle d \rangle$ **piccola**: la lunghezza media del percorso cresce come $\log N$, molto più lentamente della dimensione della rete.

2. **Alto coefficiente di clustering**: i vicini di un nodo tendono ad essere connessi tra loro (molto di più di quanto ci si aspetterebbe in un grafo casuale).

La coesistenza di questi due fenomeni è catturata dal **modello di Watts–Strogatz (1998)**: partendo da un grafo ad anello regolare, il ricablaggio casuale di una piccola frazione di archi abbassa drasticamente $\langle d \rangle$ mantenendo alto il clustering.

Capitolo 3. Legami Forti e Deboli

Comprendere come scorrono le informazioni attraverso una rete sociale è uno dei problemi centrali della sociologia moderna. Non tutti i legami sono uguali: un'amicizia intima e una conoscenza superficiale hanno ruoli strutturalmente diversi nella rete. La distinzione tra legami *forti* e *deboli* — introdotta da Mark Granovetter — è uno dei contributi teorici più influenti della Social Network Analysis, con applicazioni che vanno dalla ricerca del lavoro alla diffusione delle innovazioni, dalla prevenzione delle epidemie alle strategie di marketing virale.

L'ipotesi di Granovetter

Negli anni '60, il sociologo Mark Granovetter condusse interviste con persone che avevano cambiato lavoro. Scoprì che molti avevano appreso dell'opportunità tramite **conoscenti**, non amici intimi.

Granovetter formulò l'ipotesi della **"forza dei legami deboli"**: i legami deboli (con conoscenti distanti) fungono da *ponti* tra porzioni diverse della rete, trasmettendo informazioni nuove non disponibili nel proprio gruppo stretto.

Chiusura Triadica

Definizione (Chiusura triadica). Se A è amico di B e di C, allora esiste una probabilità elevata che B e C diventino amici nel tempo.

Ragioni della chiusura triadica:

1. **Opportunità**: B e C si incontrano attraverso A.
2. **Fiducia**: la conoscenza comune A funge da garante.
3. **Incentivo**: la tensione cognitiva spinge verso equilibrio.

Coefficiente di Clustering

Il **coefficiente di clustering locale** di un nodo i con grado k_i è:

$$C_i = \frac{2L_i}{k_i(k_i - 1)}$$

dove L_i è il numero di archi tra i vicini di i.

$C_i = 0$: nessuno dei vicini è connesso tra loro. $C_i = 1$: tutti i vicini formano un grafo completo.

Il **coefficiente di clustering medio** di una rete è:

$$\langle C \rangle = \frac{1}{N} \sum_{i=1}^{N} C_i$$

Interpretazione intuitiva. Il coefficiente di clustering risponde alla domanda: "quanto sono interconnessi tra loro i miei amici?". Il denominatore $k_i(k_i - 1)$ conta il numero massimo di archi possibili tra i k_i vicini di i (cioè tutte le coppie possibili, tenendo conto della direzione), mentre $2L_i$ conta quanti di questi archi esistono effettivamente. Se tutti i vostri amici si conoscono già tra loro, $C_i = 1$; se nessuno dei vostri amici conosce gli altri, $C_i = 0$.

Questo concetto è strettamente legato alla chiusura triadica: un coefficiente di clustering alto indica che molte triade "aperte" (A–B e A–C connessi, ma B–C no) si sono "chiuse" nel tempo. Il clustering medio $\langle C \rangle$ è una proprietà globale della rete: nelle reti sociali reali è tipicamente molto più alto di quanto ci si aspetterebbe in un grafo casuale della stessa dimensione — questa è una delle caratteristiche che definisce il *piccolo mondo*.

Ponti e Ponti Locali

Definizione (Ponte). Un arco (A, B) è un ponte se la sua rimozione disconnette A e B (li porta in componenti distinte).

Definizione (Ponte locale). Un arco (A, B) è un ponte locale se A e B non hanno nessun amico in comune. La sua rimozione aumenta la distanza $d(A, B) > 2$.

Relazione con la chiusura triadica: un arco è un ponte locale precisamente quando non forma il lato di nessun triangolo. Ponti locali e chiusura triadica sono concetti opposti.

La Proprietà di Chiusura Triadica Forte

Categorizzando i legami in **forti** (amici intimi) e **deboli** (conoscenti):

Proprietà STCP. Se un nodo A ha legami forti con B e C, allora esiste un legame (almeno debole) tra B e C.

Conseguenza. I legami deboli sono candidati naturali a essere ponti locali: se A–B fosse forte e fosse un ponte locale, violerebbero STCP. Questo spiega perché i legami deboli portano informazioni nuove.

Dimostrazione formale: ponti locali e legami deboli

Claim. Se un nodo A soddisfa la STCP ed è coinvolto in almeno due legami forti, allora qualsiasi ponte locale a cui A partecipa deve essere un legame debole.

Dimostrazione (per assurdo).

1. Supponiamo che A abbia un legame forte con B e che A–B sia un ponte locale.
2. Poiché A ha almeno due legami forti, esiste un altro nodo C con A–C forte.
3. Poiché A–B è un ponte locale, A e B non hanno amici in comune → B e C non sono connessi.
4. Ma A–B forte e A–C forte con B–C assente viola la STCP. Contraddizione. □

Quindi **i legami deboli hanno un duplice ruolo**: sono connessioni superficiali (bassa forza) ma al tempo stesso preziosi ponti verso parti distanti della rete ("la forza dei legami deboli" di Granovetter).

Esempio concreto della STCP. Considerate una persona, Alice, che ha legami forti con due colleghi di lavoro, Bob e Carlo. La STCP afferma che esiste almeno un legame debole tra Bob e Carlo. Se Alice–Bob fosse un ponte locale (Alice e Bob non hanno conoscenti in comune), allora Bob e Carlo non sarebbero connessi. Ma allora il legame Alice–Bob forte e il legame Alice–Carlo forte, senza connessione Bob–Carlo, violerebbe la STCP.

Nella pratica: perché questa situazione è instabile? Perché Alice probabilmente ha presentato Bob a Carlo in qualche occasione (festa di lavoro, riunione), creando quel legame "almeno debole" previsto dalla STCP. Il legame Bob–Carlo potrebbe rimanere debole (si salutano di tanto in tanto), ma la sua *assenza* sarebbe socialmente strana dato che entrambi conoscono bene Alice. Questo è il motivo per cui i veri "ponti" tra comunità distinte di una rete sociale sono quasi sempre legami deboli: una persona con legami forti non può essere un ponte, perché la STCP ne impedirebbe l'assenza di connessioni trasversali.

Validazione empirica: studio Onnela et al. (reti di telefonia mobile)

Per molti anni le previsioni di Granovetter rimasero difficili da verificare su larga scala. Con l'avvento delle comunicazioni digitali, Onnela et al. studiarono la rete *chi-chiama-chi* di un operatore di telefonia mobile, con milioni di nodi.

Misura continua della forza del legame. Nelle reti reali la dicotomia forte/debole è troppo rigida. La forza di un arco A–B viene definita come il tempo totale di conversazione tra A e B; si può poi ordinare tutti gli archi per percentile di forza.

Neighborhood overlap. Analogamente, la proprietà di "ponte locale" (nessun amico in comune) è rarissima nelle reti reali. Si introduce quindi una misura graduale:

$$\text{Neighborhood Overlap}(A, B) = \frac{|\mathcal{N}(A) \cap \mathcal{N}(B)|}{|\mathcal{N}(A) \cup \mathcal{N}(B)|}$$

dove $\mathcal{N}(X)$ è l'insieme dei vicini di X (escluso il nodo stesso).

- Overlap = 0: A e B non hanno vicini in comune → arco è un ponte locale.
- Overlap piccolo: arco è "quasi" un ponte locale.
- Overlap grande: arco è immerso in un gruppo fitto.

Risultato. Lo studio di Onnela et al. confermò la previsione di Granovetter: all'aumentare della forza del legame, l'overlap di vicinato cresce sistematicamente. In altre parole, i legami deboli tendono ad avere overlap basso e a fungere da ponti tra comunità distinte, mentre i legami forti collegano nodi con molti amici in comune.

Capitolo 4. Contesti Sociali e Omofilia

Omofilia

Definizione (Omofilia). Il principio per cui tendiamo ad essere simili ai nostri amici.

I legami nelle reti sociali tendono a connettere persone simili per età, etnia, luogo di residenza, occupazione, interessi e opinioni. L'omofilia può guidare la formazione di legami e rafforzare la chiusura triadica: se A–B e A–C sono amici, l'omofilia suggerisce che B e C siano già simili tra loro, aumentando la probabilità di un legame B–C.

Misurare l'Omofilia

Dato un attributo categorico (es. genere) con frazione p di nodi tipo "maschio" e frazione $q = 1 - p$ di nodi tipo "femmina":

Se i legami fossero formati casualmente, la frazione attesa di archi *eterogenei* (che collegano i due tipi) sarebbe:

$$2pq$$

Se la frazione osservata di archi eterogenei è *minore* di $2pq$, la rete mostra **omofilia**; se è *maggiore*, mostra **eterofilia** (*eterofilia*: la tendenza a legarsi con persone *diverse* da sé, ad esempio in relazioni di mentoring tra giovani e anziani).

Perché $2pq$? La formula $2pq$ deriva dal calcolo probabilistico del *mixing casuale* (*random mixing*): se ogni arco collegasse due nodi scelti indipendentemente e a caso dalla popolazione, la probabilità che un estremo cada nel gruppo A (proporzione p) e l'altro nel gruppo B (proporzione $q = 1 - p$) sarebbe $p \cdot q$. Siccome l'arco può andare "A→B" oppure "B→A", la probabilità totale di un arco eterogeneo è $2pq$. Questo è esattamente il termine del binomio $(p + q)^2 = p^2 + 2pq + q^2$, dove p^2 è la probabilità di un arco omogeneo A–A e q^2 di un arco omogeneo B–B.

Dunque, $2pq$ è il *baseline* atteso in assenza di preferenze: se osserviamo meno archi eterogenei, qualcosa (la preferenza per simili) spinge le persone a connettersi con chi è uguale a loro — questo è l'omofilia. Se osserviamo più archi eterogenei, qualcosa spinge verso il legame con persone diverse — questa è l'eterofilia.

Esempio numerico. Consideriamo una rete scolastica con 9 alunni: 6 maschi ($p = 6/9 = 2/3$) e 3 femmine ($q = 3/9 = 1/3$). La rete ha 18 archi totali, di cui 5 sono eterogeni (collegano un maschio a una femmina). Con il mixing casuale ci aspetteremmo $2pq = 2 \cdot (2/3) \cdot (1/3) = 4/9$ di archi eterogeni, ovvero $18 \times (4/9) = 8$ archi. Ne osserviamo solo $5 < 8 \rightarrow$ **evidenza di omofilia per genere**.

Note metodologiche.

1. Il numero atteso $2pq \cdot |E|$ varia per effetto del campionamento; per concludere all'omofilia occorre verificare che lo scarto sia *statisticamente significativo* (es. con un test del chi-quadro o mediante permutazioni).

2. Se la frazione di archi eterogenei è significativamente *maggiore* di $2pq$, si parla di **eterofilia** (o omofilia inversa): le persone tendono a legarsi con chi è diverso da loro.

3. Il test si estende a caratteristiche con più di due valori: un arco è *eterogeneo* se i suoi estremi hanno valori diversi, e si calcola la proporzione di archi eterogenei attesa dal mixing casuale sulla base della distribuzione dei valori nella rete.

Selezione e Influenza Sociale

Due meccanismi generano l'omofilia osservata:

- **Selezione** (*selection*): le persone formano legami con chi è già simile a loro (*"birds of a feather flock together"*). La selezione opera *prima* della formazione del legame: si sceglie come amico chi condivide già i propri valori, interessi o caratteristiche demografiche.

- **Influenza sociale** (*social influence*): i legami esistenti modificano i comportamenti e le caratteristiche degli individui (*peer pressure*). L'influenza

opera *dopo* la formazione del legame: gli amici ci convincono ad adottare certi comportamenti, opinioni o abitudini, rendendoci più simili a loro nel tempo.

Caratteristiche immutabili (sesso biologico, etnia): solo la selezione opera, perché l'influenza sociale non può cambiare queste caratteristiche.
Caratteristiche mutabili (comportamenti, opinioni, interessi): entrambi i meccanismi operano, rendendo difficile distinguere empiricamente quale dei due prevalga in un dato contesto.

Perché questa distinzione è importante? Capire quale meccanismo prevalga è fondamentale per progettare interventi efficaci. Se la somiglianza tra amici è dovuta principalmente alla *selezione*, gli interventi di salute pubblica o prevenzione dovrebbero mirare a modificare il contesto sociale (ad es. chi frequenta chi). Se è dovuta principalmente all'*influenza sociale*, è più efficace intervenire sui *leader di opinione* nella rete, perché il loro cambiamento di comportamento si propagherà ai loro contatti.

Esempio. Studi longitudinali sugli adolescenti (Cohen & Kandel) mostrano che sia selezione sia influenza sociale spiegano la somiglianza comportamentale tra amici, con l'influenza sociale più moderata della selezione. Capire quale meccanismo prevalga è fondamentale per progettare interventi efficaci (es. programmi anti-droga).

Affiliazione e Reti Bipartite

Possiamo modellare reti che includono sia **persone** sia **contesti** (focus group, club, classi, eventi) come nodi, connettendo persone ai contesti in cui partecipano. Feld (1981) chiama questi contesti **foci**: punti focali di interazione sociale. Si ottiene una **rete bipartita**: due tipi di nodi (persone e foci), archi solo tra tipi diversi.

La **proiezione** su un tipo di nodi crea archi tra persone che condividono un contesto, spiegando così l'emergere dell'omofilia anche senza scelta esplicita di amici simili.

Tipi di chiusura nelle reti sociali

Nelle reti sociali si distinguono tre forme di chiusura che guidano la formazione di nuovi legami:

- **Chiusura triadica**: B e C diventano amici perché hanno un amico comune A (entrambi sono persone).
- **Chiusura focale** (*focal closure*): B e C diventano amici perché partecipano a un focus comune A (es. stessa classe, stessa associazione).

- **Chiusura di membership** (*membership closure*): B aderisce a un focus a cui il suo amico A già partecipa (forma di influenza sociale sui foci scelti).

Co-evoluzione delle reti sociali e di affiliazione

Le reti sociali e le reti di affiliazione **co-evolvono**: la partecipazione a un focus crea opportunità di amicizia; le amicizie esistenti influenzano la scelta dei foci futuri. Questo meccanismo spiega perché l'omofilia osservata nelle reti sociali emerga in parte spontaneamente, anche in assenza di una scelta deliberata di amici simili.

Studio empirico: Kossinets & Watts. Kossinets e Watts analizzarono una rete di e-mail universitaria seguita nel tempo, integrando i dati di comunicazione con gli orari delle lezioni (ogni corso = un focus). Misurarono la probabilità giornaliera di formazione di un legame in funzione di:

- il numero di amici in comune (chiusura triadica): la probabilità cresce in modo superlineare con il numero di amici condivisi.
- il numero di corsi condivisi (chiusura focale): un singolo corso condiviso ha un effetto assoluto simile a un singolo amico in comune, ma l'effetto si satura rapidamente all'aggiunta di ulteriori corsi condivisi.

Il confronto mostra che chiusura triadica e focale sono meccanismi complementari e paragonabili per importanza nella formazione di legami.

Capitolo 5. Analisi delle Reti con R

Il pacchetto `igraph`

La libreria **igraph** (disponibile per R e Python) è lo strumento standard per l'analisi e la visualizzazione di reti. Si installa con:

```
install.packages("igraph")
library(igraph)
```

Costruzione di un grafo

```
# Grafo diretto vuoto
g <- graph.empty(directed = TRUE)

# Aggiunta di nodi (famiglia reale)
g <- g + vertex("Elizabeth II")
g <- g + vertex("Philip")
```

```
g <- g + vertex("Charles")
g <- g + vertex("Diana")
g <- g + vertex("William")
g <- g + vertex("Harry")
g <- g + vertex("Catherine")
g <- g + vertex("George")

# Aggiunta di archi (relazioni genitore -> figlio)
g <- g + edges("Elizabeth II", "Charles")
g <- g + edges("Philip",       "Charles")
g <- g + edges("Charles",      "William")
g <- g + edges("Diana",        "William")
g <- g + edges("Charles",      "Harry")
g <- g + edges("Diana",        "Harry")
g <- g + edges("William",      "George")
g <- g + edges("Catherine",    "George")

plot.igraph(g)
```

```
# Grafo da lista di archi
g1 <- graph(edges = c(1,2, 2,3, 3,1), n = 3, directed =
   FALSE)
plot(g1)

# Grafo con nomi
g3 <- graph(c("John","Jim","Jim","Jill","Jill","John"))
plot(g3)

# Grafo da formula letterale
plot(graph_from_literal(a---b, b---c))  # non orientato
plot(graph_from_literal(a--+b, b+--c)) # orientato
```

Lettura di dati da file

```
# Dataset 1: rete media (orientata, lista di archi)
nodes <- read.csv("Dataset1-Media-Example-NODES.csv",
                  header = TRUE, as.is = TRUE)
links <- read.csv("Dataset1-Media-Example-EDGES.csv",
                  header = TRUE, as.is = TRUE)
net <- graph_from_data_frame(d = links, vertices = nodes,
                             directed = TRUE)
```

```
plot(net, edge.arrow.size = 0.4, edge.curved = 0.1)
```

```
# Dataset 2: rete bipartita (matrice di incidenza)
nodes2 <- read.csv("Dataset2-Media-User-Example-NODES.csv",
                   header = TRUE, as.is = TRUE)
links2 <- read.csv("Dataset2-Media-User-Example-EDGES.csv",
                   header = TRUE, row.names = 1)
links2 <- as.matrix(links2)
net2   <- graph_from_incidence_matrix(links2)
table(V(net2)$type)  # numero nodi per tipo
plot(net2, vertex.label = NA)
```

Visualizzazione avanzata

```
# Colori per tipo di medium
colrs <- c("gray50", "tomato", "gold")
V(net)$color <- colrs[V(net)$media.type]

# Dimensione nodi proporzionale al grado
V(net)$size <- degree(net) * 2

# Stile degli archi
E(net)$width  <- E(net)$weight / 5
E(net)$arrow.size <- 0.3

plot(net,
     vertex.label = V(net)$media,
     vertex.label.color = "black",
     vertex.label.cex = 0.7,
     layout = layout_with_fr(net))
```

```
# Rete bipartita con proiezioni
net2.bp <- bipartite.projection(net2)
plot(net2.bp$proj1,
     vertex.label.color = "black",
     vertex.label.dist  = 1,
     vertex.label = nodes2$media[!is.na(nodes2$media.type)])

```

```
# Layout bipartito esplicito
plot(net2, vertex.label = NA, vertex.size = 7,
     layout = layout_as_bipartite)
```

Capitolo 6. Misure di Centralità e Citation Networks

Centralità nelle reti

Dire che un nodo è "importante" in una rete è ambiguo: importante in che senso? Il concetto di **centralità** cerca di catturare questa intuizione in modo preciso, ma esistono molte definizioni diverse — ognuna risponde a una domanda leggermente diversa su cosa significhi essere centrale. Un nodo può essere centrale perché ha molti vicini diretti (degree centrality), perché si trova su molti cammini che collegano altri nodi (betweenness), perché è vicino a tutti gli altri (closeness), oppure perché è collegato a nodi a loro volta importanti (eigenvector centrality). La scelta della misura dipende dal fenomeno che si vuole studiare: per la diffusione rapida di un'informazione si usa la closeness; per identificare i broker di informazione si usa la betweenness; per capire chi ha più influenza indiretta si usa la centralità di autovettore.

Centralità di grado (*Degree Centrality*)

Il nodo più connesso è quello con il grado massimo:

$$C_D(i) = k_i$$

La **centralità di grado** è la misura più semplice e intuitiva: conta quanti vicini diretti ha un nodo. È particolarmente informativa in reti dove i collegamenti diretti determinano l'accesso alle risorse o alle informazioni — ad esempio, nelle reti di diffusione di malattie, un nodo con grado alto è un superspreader potenziale. Tuttavia, la centralità di grado ha i suoi limiti: non distingue tra nodi che sono connessi a "hub" influenti e nodi che sono connessi a nodi periferici — due nodi con lo stesso grado possono avere ruoli strutturali molto diversi nella rete.

Centralità di betweenness

La **betweenness centrality** misura quante volte un nodo si trova sui cammini più corti tra coppie di nodi:

$$C_B(i) = \sum_{s \neq i \neq t} \frac{\sigma_{st}(i)}{\sigma_{st}}$$

dove σ_{st} è il numero di cammini più corti tra s e t, e $\sigma_{st}(i)$ quanti di essi passano per i.

I nodi con alta betweenness sono **broker** di informazione.

Intuizione: il casello autostradale. Immaginate la rete come una mappa stradale in cui si vuole viaggiare dal nodo s al nodo t seguendo le strade più brevi. Alcuni incroci (nodi) si trovano su quasi tutti i percorsi ottimali: questi sono i nodi con alta betweenness, gli equivalenti dei caselli autostradali o dei nodi di smistamento. Chi controlla questi nodi ha un potere di intermediazione enorme: può rallentare, filtrare o distorcere il flusso di informazioni che li attraversa. Nelle reti sociali, i broker sono spesso individui che collegano comunità diverse; nelle reti aziendali, possono essere manager di livello medio che aggregano e traducono informazioni tra livelli gerarchici.

Il valore $\sigma_{st}(i)/\sigma_{st}$ rappresenta la *frazione* dei cammini ottimali tra s e t che passano per i: se esiste un solo cammino più breve e passa per i, contribuisce 1; se ci sono 10 cammini più brevi e solo 3 passano per i, contribuisce 0,3. La somma su tutte le coppie (s, t) dà la betweenness totale.

Centralità di vicinanza (*Closeness Centrality*)

$$C_C(i) = \frac{N-1}{\sum_{j \neq i} d(i,j)}$$

Un nodo con alta closeness raggiunge rapidamente tutti gli altri.

Quando usare la closeness. La closeness misura la distanza media inversa di un nodo da tutti gli altri: un valore alto indica che il nodo è "vicino al centro" della rete. La formula $N-1$ al numeratore normalizza la misura in modo che il valore massimo sia 1 (raggiunto da un nodo connesso direttamente a tutti gli altri). La closeness è più utile della betweenness quando si studia la *velocità di diffusione*: un nodo con alta closeness può diffondere un'informazione a tutta la rete in meno passi. Ad esempio, in una campagna di vaccinazione, vaccinare prima gli individui con alta closeness riduce il tempo di immunizzazione della popolazione. La closeness però è meno robusta su reti disconnesse: se il grafo non è connesso, la somma delle distanze può essere infinita (si usa spesso la variante "harmonic centrality" che somma gli inversi delle distanze).

Centralità di autovettore (*Eigenvector Centrality*)

La centralità di autovettore assegna importanza a un nodo in base all'importanza dei suoi vicini:

$$C_E(i) = \frac{1}{\lambda} \sum_{j \in \mathcal{N}(i)} C_E(j)$$

In notazione matriciale: $\mathbf{A}\,\mathbf{x} = \lambda\,\mathbf{x}$ dove $\mathbf{x}$ è l'autovettore associato all'autovalore massimo. PageRank di Google è una variante.

Il collegamento con PageRank. La centralità di autovettore cattura l'idea che "non conta solo quanti amici hai, ma anche quanto sono importanti i tuoi amici". Un nodo connesso a cinque hub importanti sarà più centrale di un nodo connesso a cento nodi periferici. La soluzione autovettoriale garantisce la coerenza: se aumenta la centralità di un vicino, aumenta anche quella del nodo.

PageRank (Brin & Page, 1998), l'algoritmo originale di Google, è una variante della centralità di autovettore che aggiunge due elementi: (1) un termine di *damping* che tiene conto del fatto che un utente casuale che naviga il web ha una probabilità $1-\alpha$ di saltare a una pagina casuale in ogni passo ($\alpha \approx 0.85$); (2) la normalizzazione per il grado uscente, in modo che pagine con molti link in uscita "diluiscano" il loro voto. La formula è $PR(i) = \frac{1-\alpha}{N} + \alpha \sum_{j \to i} \frac{PR(j)}{k_j^{out}}$. Questa variante rende l'algoritmo più robusto agli abusi (pagine create artificialmente per aumentare il PageRank) e garantisce la convergenza anche in grafi non completamente connessi.

Applicazione: Citation Networks con R

```r
library(igraph)

# Caricamento dati
allCounts <- as.matrix(read.csv("ac.csv", as.is = TRUE))
G <- graph.edgelist(allCounts, directed = FALSE)

# Sottografo su specifici temi
themes <- read.csv("themes.csv", as.is = TRUE)
matchingCases    <- which(themes$issue %in% c(20040,
   20050))
matchingCases_ids <- themes$usid[matchingCases]
H <- induced.subgraph(G, matchingCases_ids)

# Layout di Fruchterman-Reingold
set.seed(1)
lout <- layout.fruchterman.reingold(H)
plot.igraph(H, layout = lout, vertex.size = 5,
            vertex.label.cex = 0.5)
```

```r
# Eigenvector Centrality
eigenCent <- evcent(H)$vector
sort(eigenCent, decreasing = TRUE)[1:10]

# Colorazione heat map per centralita'
```

```r
bins     <- unique(quantile(eigenCent, seq(0, 1, length.out = 30)))
vals     <- cut(eigenCent, bins, labels = FALSE, include.lowest = TRUE)
colorVals <- rev(heat.colors(length(bins)))[vals]
V(H)$color <- colorVals
plot.igraph(H, vertex.label = NA, vertex.size = 5)

# Betweenness Centrality
betweenCent <- betweenness(H)
sort(betweenCent, decreasing = TRUE)[1:10]
cor(betweenCent, eigenCent)   # correlazione tra le due misure
```

Comunità: algoritmo di Girvan–Newman

Partizionamento dei grafi. L'obiettivo è suddividere un grafo in **regioni dense** (comunità) con connessioni sparse tra di esse. Esistono due famiglie principali di metodi:

- **Metodi divisivi** (top-down): identificano e rimuovono gli archi di collegamento tra comunità, a partire dall'intero grafo.
- **Metodi agglomerativi** (bottom-up): partono dai singoli nodi e li uniscono progressivamente nelle stesse comunità sulla base di criteri di similarità.

Betweenness degli archi (*Edge Betweenness*). Per selezionare quale arco rimuovere nei metodi divisivi si usa la **betweenness degli archi**: la quantità totale di flusso che passa per quell'arco. Formalmente, si suppone che per ogni coppia di nodi (s, t) esista un'unità di flusso che si distribuisce equamente sui cammini più corti da s a t; la betweenness dell'arco (u, v) è la somma di questi flussi su tutte le coppie.

$$C_B(u, v) = \sum_{s \neq t} \frac{\sigma_{st}(u, v)}{\sigma_{st}}$$

Gli archi con alta betweenness sono "ponti" tra comunità; i nodi con alta betweenness (node betweenness) **occupano buchi strutturali** (*structural holes*) e fungono da intermediari di informazione.

Il metodo di Girvan–Newman è un metodo divisivo basato sulla betweenness degli archi:

1. Calcola la betweenness di tutti gli archi.
2. Rimuove l'arco (o gli archi) con betweenness massima.

3. Ricalcola la betweenness di tutti gli archi rimasti (la rimozione altera i cammini più corti).

4. Ripete finché non rimangono archi.

Il metodo è efficace su reti di dimensioni moderate (qualche migliaio di nodi); per reti più grandi il ricalcolo iterativo della betweenness diventa computazionalmente costoso, rendendo preferibili metodi agglomerativi o approssimazioni.

```
# Rilevamento comunita' tramite edge betweenness
w <- edge.betweenness.community(H)
sort(table(w$membership))    # distribuzione delle comunita'
```

Capitolo 7. Visualizzazione dei Dati

Principi fondamentali

Una buona visualizzazione deve:

1. Mostrare i dati veritieramente, senza distorsioni.

2. Facilitare il confronto.

3. Essere comprensibile al pubblico di riferimento.

4. Scegliere il tipo di grafico adatto al tipo di dato.

ggplot2 in R

ggplot2 implementa la *Grammar of Graphics*: ogni visualizzazione si compone di dati, mapping estetici (*aesthetics*) e oggetti geometrici (*geom*).

```
library(ggplot2)

# Scatterplot base
ggplot(data = mpg) +
  geom_point(mapping = aes(x = displ, y = hwy))

# Colore per classe
ggplot(data = mpg) +
  geom_point(mapping = aes(x = displ, y = hwy, color =
     class))

# Dimensione per classe
```

```r
ggplot(data = mpg) +
  geom_point(mapping = aes(x = displ, y = hwy, size =
     class))

# Facets (griglia di grafici per sotto-gruppi)
ggplot(data = mpg) +
  geom_point(mapping = aes(x = displ, y = hwy)) +
  facet_wrap(~ class)
```

```r
# Curva smoothing
ggplot(data = mpg) +
  geom_smooth(mapping = aes(x = displ, y = hwy))

# Linee differenti per tipo di trazione
ggplot(data = mpg) +
  geom_smooth(mapping = aes(x = displ, y = hwy, linetype =
      drv))

# Combinare piu' geom
ggplot(data = mpg) +
  geom_point(mapping  = aes(x = displ, y = hwy)) +
  geom_smooth(mapping = aes(x = displ, y = hwy))
```

Esempio: Salari dei professori

```r
library(car)
data(Salaries)

# Correlazione tra stipendio e anni dal PhD
with(Salaries, cor(salary, yrs.since.phd))   # ~0.42
with(Salaries, cor(salary, yrs.service))     # ~0.33

# Test di correlazione
with(Salaries, cor.test(salary, yrs.since.phd))
```

Buone pratiche

- Evitare grafici a torta per più di 4-5 categorie (preferire barplot).
- Non troncare l'asse Y (a meno che non sia esplicitamente giustificato).
- Usare colori accessibili (palette friendly per daltonici).

- Includere sempre assi etichettati, titolo e fonte dei dati.
- Scegliere la scala appropriata (lineare vs. logaritmica).

Capitolo 8. Filtraggio Dati e Text Analysis

Dataset NYT / COVID-19

L'analisi del testo (*text analysis*) è una delle applicazioni più importanti della Social Network Analysis moderna, perché i dati social sono in larga parte testuali: post, commenti, tweet, articoli. Prima di analizzare un testo, occorre trasformarlo in una rappresentazione numerica che un algoritmo possa elaborare. Questa fase di **pre-elaborazione** è critica: scelte sbagliate in questa fase possono rendere l'analisi inutile o fuorviante.

Un **corpus** è una raccolta strutturata di documenti testuali su cui si eseguono le analisi. Ogni documento può essere un post, un articolo, un tweet, ecc. Le principali operazioni di pre-elaborazione sono: la **tokenizzazione** (suddivisione del testo in unità elementari, i *token*: parole, punteggiatura, simboli), la rimozione delle **stopwords** (parole grammaticali molto frequenti ma prive di significato semantico, come "il", "la", "di", "the", "a"), la normalizzazione del caso (tutto minuscolo), e la creazione di **n-grammi** (sequenze di n token consecutivi che catturano frasi ricorrenti, ad es. "New York", "social network").

L'analisi testuale del corso utilizza un corpus di post Facebook del *New York Times* relativi alla pandemia COVID-19. Il workflow di preprocessing è il seguente.

```r
posts <- read.csv("nyt_posts.csv")
posts <- posts[, -(37:40)]     # rimozione colonne inutili
dim(posts)

# Filtraggio per engagement minimo
p <- posts[posts$Likes > 4 & posts$Comments > 4 &
   posts$Shares > 4, ]
paste0(round(dim(p)[1] / dim(posts)[1], 2) * 100, "%")

# Estrazione ID post dall'URL
library(stringr)
p$post_id <- str_sub(p$URL, 43, 60)
table(p$Type)
```

```r
# Selezione post con "COVID-19" nel testo
m <- as.character(df_other$text)
y <- which(unlist(lapply(m, function(x) {
```

```
        grepl("COVID-19", x, ignore.case = TRUE)
     }))
posts_covid_m <- df_other[y, ]
```

Pre-elaborazione del testo con `quanteda`

La libreria `quanteda` per R implementa un workflow completo di pre-elaborazione testuale. Il risultato finale è una **Document-Feature Matrix (DFM)**: una matrice in cui ogni riga è un documento e ogni colonna è un termine (o n-gramma); il valore della cella (d, t) è la frequenza del termine t nel documento d. Questa matrice è tipicamente *molto sparsa*: la maggior parte dei termini appare in pochissimi documenti, quindi la maggior parte dei valori è zero. La DFM è la rappresentazione di input standard per molti algoritmi di analisi testuale, tra cui TF-IDF e il topic modeling.

```
library(quanteda)
source("stopwords_extended.R")

# Costruzione del corpus
corpus <- corpus(posts_covid_lm, text_field = "text")

# Tokenizzazione e pulizia
doc.tokens <- tokens(corpus)
doc.tokens <- tokens(doc.tokens,
                     remove_punct   = TRUE,
                     remove_numbers = TRUE)
doc.tokens <- tokens_select(doc.tokens,
                 stopwords(language = "en", source = "
                    snowball"),
                 selection = "remove")
doc.tokens <- tokens_select(doc.tokens, stopmore,
                             selection = "remove")
doc.tokens <- tokens_tolower(doc.tokens)
toks_ngram  <- tokens_ngrams(doc.tokens, n = 1:2)

# Document-Feature Matrix (DFM)
dfmat1 <- dfm(toks_ngram) |> dfm_trim(min_termfreq = 10)
dfmat1
```

TF-IDF

Il peso **TF-IDF** (*Term Frequency – Inverse Document Frequency*) misura l'importanza di un termine t in un documento d rispetto a un corpus D:

$$\mathrm{TF}(t,d) = \frac{f_{t,d}}{\sum_{t'} f_{t',d}} \qquad \mathrm{IDF}(t,D) = \log \frac{|D|}{|\{d \in D : t \in d\}|}$$

$$\text{TF-IDF}(t,d,D) = \mathrm{TF}(t,d) \times \mathrm{IDF}(t,D)$$

Termini molto frequenti in tutto il corpus (es. "the", "a") ricevono IDF basso e quindi peso basso, mentre termini specifici di pochi documenti ricevono peso alto.

Spiegazione dettagliata. Il **TF** (*Term Frequency*) di un termine t nel documento d è $\mathrm{TF}(t,d) = f_{t,d}/\sum_{t'} f_{t',d}$: il rapporto tra il numero di volte che t appare in d e il numero totale di termini in d. La normalizzazione elimina il vantaggio dei documenti lunghi. Un termine che appare 10 volte in un documento di 100 parole ha lo stesso TF di uno che appare 100 volte in un documento di 1000 parole.

L'**IDF** (*Inverse Document Frequency*) vale $\log(|D|/|\{d \in D : t \in d\}|)$: il logaritmo del rapporto tra il numero totale di documenti $|D|$ e il numero di documenti che contengono il termine t. Se t appare in tutti i documenti, $\mathrm{IDF} = \log(1) = 0$: il termine è così comune da non avere valore discriminante. Se t appare in un solo documento su 1000, $\mathrm{IDF} = \log(1000) \approx 6.9$: il termine è molto specifico e discriminante. Il logaritmo smorza la crescita dell'IDF per termini rarissimi.

Il prodotto **TF-IDF** premia quindi i termini che sono frequenti nel singolo documento (TF alto) ma rari nel corpus (IDF alto): sono i termini che meglio distinguono il documento dagli altri. Questa misura è utilizzata per estrarre parole chiave, costruire rappresentazioni vettoriali dei documenti per il *retrieval* di informazioni, e come input per algoritmi di classificazione e clustering testuale.

```r
library(quanteda.textstats)

# 100 termini piu' frequenti
features_dfm <- textstat_frequency(dfmat1, n = 100)

# TF-IDF
dfmat_tfidf <- dfm_tfidf(dfmat1)
```

Analisi del sentimento

L'analisi del sentimento assegna a testi un punteggio di valenza emotiva (positivo, negativo, neutro). Approcci principali:

- **Dizionari lessicali** (es. AFINN, BING, NRC): lookup diretto.

- **Modelli ML supervisionati**: classificatori addestrati su testi annotati.
- **Modelli basati su trasformatori** (BERT): catturano il contesto.

Capitolo 9. Topic Modeling con BERTopic

Cos'è il Topic Modeling?

Il **topic modeling** è una tecnica di apprendimento non supervisionato per scoprire temi latenti in un corpus di testi. Dato un insieme di documenti (tweet, articoli, commenti, ecc.), l'obiettivo è assegnare automaticamente ogni documento a uno o più argomenti.

Rappresentazione dei documenti

Bag of Words (BoW). Ogni documento è rappresentato dalla frequenza delle sue parole (vettore sparso).

✓ Semplice, interpretabile.

× Perde informazione sintattica e semantica; problemi con omonimia ed enantiosemia.

Esempio concreto. Considerate il documento "il cane mangia il gatto". Dopo la tokenizzazione e la rimozione delle stopwords ("il"), rimangono i token: {cane, mangia, gatto}. Il vocabolario del corpus è ad esempio {cane, gatto, mangia, dorme, vola}. Il vettore BoW di questo documento è $(1, 1, 1, 0, 0)$: 1 per cane, 1 per gatto, 1 per mangia, 0 per dorme, 0 per vola. Un documento "il gatto dorme" diventerebbe $(0, 1, 0, 1, 0)$.

Notate che l'informazione sull'ordine delle parole è persa: "il cane mangia il gatto" e "il gatto mangia il cane" producono lo stesso vettore BoW. Questa è la limitazione fondamentale del BoW: non cattura il significato sintattico né il contesto. Un'ulteriore limitazione è l'omonimia: la parola "banco" (di scuola vs. di pesci vs. istituto di credito) produce lo stesso token ma ha significati completamente diversi a seconda del contesto.

Embeddings (word2vec, BERT). Ogni parola/frase viene mappata in un vettore denso nello spazio $\mathbb{R}^d$ dove la similarità vettoriale riflette la similarità semantica.
Esempio concreto di embedding semantico. In uno spazio di embedding ben addestrato, le parole "re" e "regina" hanno vettori vicini (alta similarità coseno), così come "cane" e "gatto". Ma la relazione è ancora più ricca: la differenza vettoriale $\vec{re} - \vec{uomo} + \vec{donna} \approx \vec{regina}$ cattura la relazione semantica "re sta a uomo

come regina sta a donna". Allo stesso modo, frasi con significato simile come "il treno è in ritardo" e "il convoglio ferroviario ha accumulato del ritardo" producono embedding molto vicini nello spazio $\mathbb{R}^d$, anche se non condividono quasi nessuna parola. Questo è il vantaggio fondamentale rispetto al BoW: due documenti possono essere semanticamente simili pur usando vocabolari diversi.

Il modello **BERT** (*Bidirectional Encoder Representations from Transformers*, 2018) legge il testo in entrambe le direzioni e produce rappresentazioni contestuali. **Sentence-BERT** (SBERT, 2019) usa il *mean pooling* sulle rappresentazioni per ottenere un embedding a livello di frase.

- ✓ Nessun preprocessing testuale specifico; mantiene il contesto.
- × Non interpretabile; limite di lunghezza (∼500 token ≈ 300 parole); può risentire di bias nel corpus di addestramento.

La maledizione della dimensionalità (*Curse of Dimensionality*). Dopo l'embedding, ogni documento è un punto in uno spazio con centinaia di dimensioni ($d \approx 768$ per BERT). In spazi ad altissima dimensione il concetto di "distanza" perde significato: quasi tutte le coppie di punti diventano equidistanti, rendendo il clustering inefficace. Per questo BERTopic introduce un passo di **riduzione della dimensionalità** prima del clustering.

Intuizione geometrica. In uno spazio a 1 dimensione (una linea), due punti casuali nell'intervallo $[0, 1]$ hanno in media una distanza di circa $1/3$. In uno spazio a d dimensioni, la distanza media tra due punti casuali nel cubo unitario cresce come $\sqrt{d/6}$, mentre la distanza minima cresce molto più lentamente. In pratica, per d molto grande, il rapporto tra la distanza massima e quella minima tende a 1: tutti i punti sembrano equidistanti. Questo significa che in $\mathbb{R}^{768}$ è quasi impossibile distinguere un vicino da un punto lontano, rendendo algoritmi basati sulla distanza (come il clustering) fondamentalmente inutili senza pre-elaborazione. UMAP risolve questo problema proiettando i dati in $\mathbb{R}^5$ o $\mathbb{R}^{10}$, dove le distanze sono di nuovo significative e i cluster sono visibili.

Il pipeline di BERTopic

BERTopic (Grootendorst, 2022) combina quattro passi:

1. **Embedding dei documenti** tramite SBERT: ogni documento diventa un vettore in uno spazio ad alta dimensione ($d \approx 768$).
2. **Riduzione della dimensionalità** con UMAP: da $\mathbb{R}^{768}$ a $\mathbb{R}^5$ (o meno), preservando la struttura locale.

3. **Clustering** con HDBSCAN: raggruppa documenti semanticamente simili in cluster; i documenti fuori da tutti i cluster sono etichettati come "rumore".
4. **Rappresentazione dei topic** con c-TF-IDF: per ogni cluster si calcola un TF-IDF "classico" applicato ai cluster come fossero documenti.

UMAP (Uniform Manifold Approximation and Projection). UMAP riduce la dimensionalità preservando la struttura locale dei dati:

1. Costruisce un grafo di vicinanza nello spazio ad alta dimensione.
2. Costruisce un grafo equivalente in bassa dimensione.
3. Minimizza la *cross-entropy loss* tra i due grafi tramite discesa del gradiente stocastica.

Il risultato è una proiezione che preserva i cluster semantici. La qualità dipende dal parametro K (numero di vicini considerati).

Algoritmi di clustering: da K-Means a HDBSCAN. **K-Means** è l'algoritmo di clustering più semplice: si scelgono K centroidi, si assegna ogni punto al centroide più vicino, si ricalcolano i centroidi, e si ripete fino alla convergenza. Limitazione principale: richiede di specificare K a priori e produce cluster di forma sferica.

DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) supera questi limiti: individua cluster di forma arbitraria sulla base della densità locale (parametri: raggio ε e numero minimo di punti `minPts`), e classifica i punti isolati come **rumore**. Complessità media $O(n \log n)$.

HDBSCAN (*Hierarchical DBSCAN*) estende DBSCAN:

- non richiede di specificare il numero di cluster *a priori*;
- individua cluster di forma arbitraria e con densità diverse;
- richiede un solo iperparametro principale (dimensione minima del cluster);
- etichetta come rumore i punti in regioni a bassa densità.

c-TF-IDF (class-TF-IDF). Per ottenere le parole rappresentative di ogni topic, BERTopic unisce tutti i documenti di un cluster in un unico "meta-documento" e calcola:

$$c\text{-TF-IDF}_{t,c} = \frac{f_{t,c}}{\sum_{t'} f_{t',c}} \times \log\left(1 + \frac{A}{f_t}\right)$$

dove $f_{t,c}$ è la frequenza di t nel cluster c, f_t è la frequenza totale di t nel corpus, e A è il numero medio di parole per classe.

Altre rappresentazioni dei topic. BERTopic supporta rappresentazioni alternative alla c-TF-IDF:

- **Marginal Maximum Relevance (MMR)**: bilancia rilevanza e diversità delle parole chiave.
- **Part of Speech (POS)**: filtra le parole chiave per categoria grammaticale.
- **KeyBERT**: usa gli embedding BERT per trovare le parole più simili semanticamente al topic.
- **LLM**: sfrutta modelli di linguaggio di grandi dimensioni per generare etichette o riassunti testuali per ciascun topic.

Valutazione del modello

BERTopic richiede la scelta di diversi iperparametri (embedding model, numero di vicini UMAP, dimensione minima del cluster HDBSCAN, lingua per le stopword). La valutazione avviene sia quantitativamente sia qualitativamente.

Metriche quantitative:

- **DB Cluster Relative Validity (DBCV)**: misura la qualità del clustering tra -1 e 1; valori più alti indicano cluster più coesi e separati. Permette di confrontare diversi run con parametri diversi sullo stesso corpus.
- **Coherence score**: misura la coerenza semantica dei topic, valutando quanto spesso le parole chiave di un topic co-occorrono nel corpus.
- **Diversity score** (es. Jaccard Topic Diversity): misura quanto i topic siano distinti tra loro calcolando la proporzione di parole chiave uniche sul totale.

Ispezione manuale: la lettura delle parole chiave e dei documenti rappresentativi di ciascun topic rimane il metodo più affidabile ma richiede molto tempo.

Vantaggi e limiti di BERTopic

Vantaggi	Limiti
Scalabile a grandi corpus	Richiede GPU per l'embedding
Preserva il contesto semantico	Molti iperparametri da ottimizzare
Flessibile (componenti sostituibili)	Limite di lunghezza dei documenti
Topic interpretabili tramite parole chiave	Possibili bias dal corpus di pre-addestramento

Varianti di BERTopic

- **Dynamic Topic Modeling**: evoluzione dei topic nel tempo.
- **Guided Topic Modeling**: incorporazione di seed words.
- **Zero-shot Topic Modeling**: classificazione senza dati di addestramento.
- **Online Topic Modeling**: aggiornamento incrementale del modello.

Capitolo 10. Big Data e Dati Sociali

Cosa sono i Big Data?

"*Big Data*" è un termine spesso frainteso: non si riferisce semplicemente a grandi quantità di dati, ma a una **capacità di ricerca, aggregazione e incrocio** di insiemi di dati eterogenei (Boyd & Crawford, 2012).

Due interpretazioni prevalenti:

1. **Strumento potente**: permette di affrontare questioni sociali complesse su larga scala.
2. **Manifestazione preoccupante**: rischi per la privacy, la libertà civile e il controllo governativo/corporativo.

Le **quattro forze regolatrici** dei sistemi sociali (Lessig, 1999):

- **Mercato**: i Big Data rappresentano un'opportunità commerciale enorme.
- **Legge**: i Big Data sollevano preoccupazioni sulla privacy e la protezione dei dati personali (es. GDPR).
- **Norme sociali**: la personalizzazione algoritmica è vista come utile (informazioni più rilevanti) ma anche come fonte di frammentazione del dibattito pubblico (camere d'eco).
- **Architettura (codice)**: le piattaforme digitali progettano ambienti che modellano i comportamenti degli utenti, spesso in modo opaco.

Queste forze sono spesso in conflitto nell'ecosistema dei Big Data.

Sei provocazioni sui Big Data (Boyd & Crawford)

1. I Big Data cambiano la definizione di conoscenza. L'emergere di sistemi computazionali per l'analisi dei dati modifica il modo in cui costruiamo conoscenza scientifica e sociale. I tool disponibili hanno limitazioni strutturali (es. archivi Twitter/Facebook di difficile accesso) che condizionano le domande di ricerca.

2. I claim di obiettività e accuratezza sono fuorvianti. Tutti i ricercatori interpretano i dati. Le scelte di design (cosa misurare, come pulire i dati, quali variabili includere) sono soggettive. I grandi dataset possono contenere errori sistematici che si amplificano con la combinazione di fonti diverse.

3. I Big Data non sono equivalenti ai Big Data. L'accesso ai dati non è democratico: grandi aziende e governi hanno accesso privilegiato che i ricercatori accademici non hanno. I dati disponibili dipendono da scelte commerciali e politiche, non dalla rilevanza scientifica.

4. I Big Data estrapolati dal contesto perdono significato. I dati social sono ampiamente usati per fare affermazioni sulle reti sociali, ma le relazioni rappresentate sui social media non equivalgono necessariamente alle reti personali studiate dai sociologi attraverso interviste e osservazioni.

Boyd e Crawford distinguono due tipi di reti sociali nei Big Data:

- **Reti articolate** (*articulated networks*): derivate da dichiarazioni esplicite degli utenti (liste di amici/follower). Includono amici intimi, conoscenti, colleghi, celebrity, ecc.
- **Reti comportamentali** (*behavioral networks*): derivate da pattern di comunicazione e interazione effettiva sulla piattaforma.

Entrambe hanno valore per i ricercatori, ma non sono equivalenti tra loro né alle reti personali reali. Ad esempio, la frequenza dei contatti non indica necessariamente la forza del legame, e non ogni connessione corrisponde a un'altra connessione.

5. Le questioni etiche sono complesse.

- **Consenso informato**: i dati social sono pubblici, ma non necessariamente ceduti per scopi di ricerca. Il fatto che un utente abbia pubblicato un contenuto su Facebook non significa che acconsenta al suo uso in una ricerca scientifica.
- **Anonimizzazione e re-identificazione**: dati apparentemente anonimi possono essere re-identificati combinando attributi. Un caso emblematico è lo studio di Lewis et al. (2008), in cui un gruppo di ricercatori di Harvard raccolse i profili Facebook di circa 1.700 studenti e li rese disponibili come dataset di ricerca. Il ricercatore Zimmer mostrò che la re-identificazione era possibile: includendo genere, stato di provenienza, corso di laurea ed etnia, i soggetti diventavano facilmente identificabili (es. l'unico studente albanese di un college privato del New England con circa 1.640 matricole). Gli autori dello studio

risposero che i dati erano già presenti su Facebook, ma Zimmer controbatté che postare su Facebook non equivale a dare il consenso alla ricerca scientifica.

- **Discriminazione algoritmica**: modelli addestrati su dati storici possono perpetuare discriminazioni.

6. Accesso asimmetrico ai Big Data crea nuove disparità. La divisione tra chi ha e chi non ha accesso ai grandi dataset crea disuguaglianze nella produzione di conoscenza e nel potere decisionale.

Nota metodologica: correlazioni e causalità. Una limitazione trasversale all'analisi dei Big Data è che la correlazione statistica tra variabili non implica un nesso causale. I grandi dataset facilitano la scoperta di pattern ma non necessariamente la loro spiegazione causale. Occorre rigore metodologico per non trarre conclusioni errate.

Qualità dei dati sociali e tassonomia dei bias (Olteanu et al., 2019)

La raccolta e l'analisi dei dati social introduce sistematicamente dei bias che il ricercatore deve riconoscere e, per quanto possibile, controllare. Olteanu et al. (2019) propongono una tassonomia articolata in sei categorie:

1. **Population biases**: differenze demografiche tra gli utenti di una piattaforma e la popolazione target. Le principali piattaforme social presentano composizioni demografiche sistematicamente diverse dalla popolazione generale (es. divari per genere, età, etnia). Assumere che i dati siano rappresentativi della popolazione porta a conclusioni fuorvianti.

2. **Behavioral biases**: differenze nel comportamento degli utenti across piattaforme o contesti. Includono:

    - *Interaction biases*: come gli utenti interagiscono tra loro varia per relazione, demografia e funzionalità della piattaforma.
    - *Content consumption biases*: gli utenti tendono a consumare contenuti di persone simili, favorendo la formazione di *echo chambers*.
    - *Self-selection e misreport*: gli utenti pubblicano selettivamente (autocensura, rimozione contenuti) e possono dare auto-report inaccurati.

3. **Content production biases**: differenze lessicali, sintattiche e semantiche nei contenuti prodotti da popolazioni diverse. L'uso della lingua varia tra paesi, gruppi demografici e nel tempo; utenti "esperti" producono contenuti diversi da utenti normali.

4. **Linking biases**: differenze negli attributi delle reti costruite da connessioni o interazioni degli utenti. Le reti basate su connessioni esplicite (es. amici dichiarati) sono strutturalmente diverse da quelle basate su interazioni implicite (es. chi risponde a chi). L'omofilia può distorcere sistematicamente le percezioni degli utenti sulla prevalenza di certi attributi nella popolazione.

5. **Temporal variations**: variazioni nelle popolazioni, nei comportamenti e nelle piattaforme nel tempo. Includono fenomeni stagionali/periodici, eventi improvvisi (es. catastrofi naturali), cambiamenti di funzionalità della piattaforma, e il decadimento dei dataset nel tempo (cancellazione di account, restrizioni API).

6. **Functional biases**: bias derivanti dai meccanismi specifici delle piattaforme. Ogni piattaforma ha le proprie affordances (azioni incentivate o disincentivate) e algoritmi proprietari (spesso non documentati) che modellano il comportamento degli utenti e la distribuzione dei contenuti. Ad esempio, ridimensionare la finestra di risposta su Facebook ha portato risposte più brevi, più frequenti e più rapide.

Ridondanza. Un ulteriore problema è la **ridondanza**: lo stesso contenuto può apparire in copie esatte (*duplicati*) o approssimate (*near-duplicates*), distorcendo la quantificazione dei fenomeni. La ridondanza può però essere anche un *segnale* (es. un messaggio ripubblicato molte volte indica viralità).

Attributi privati nei dati digitali

La ricerca di Kosinski et al. (2013) dimostrò che i *Facebook likes* permettono di prevedere con alta accuratezza attributi privati degli utenti (orientamento sessuale, etnia, opinioni politiche, tratti della personalità). Questo solleva questioni etiche fondamentali sull'uso dei dati digitali.

Capitolo A. Formulario riassuntivo

Misura	Formula	Interpretazione
Grado (non or.)	$k_i = \sum_j A_{ji}$	Numero di vicini
Grado medio	$\langle k \rangle = 2L/N$	Connettività media
Clustering loc.	$C_i = \frac{2L_i}{k_i(k_i-1)}$	Densità locale
Clustering medio	$\langle C \rangle = \frac{1}{N} \sum C_i$	Clustering globale
Betweenness	$C_B(i) = \sum_{s \neq i \neq t} \frac{\sigma_{st}(i)}{\sigma_{st}}$	Ruolo di intermediario
Closeness	$C_C(i) = \frac{N-1}{\sum_{j \neq i} d(i,j)}$	Efficienza di raggiungimento
Eigenvector	$\mathbf{Ax} = \lambda \mathbf{x}$	Importanza dei vicini
TF-IDF	$\text{TF} \times \log(\lvert D \rvert / \text{df})$	Rilevanza termine in doc

Capitolo B. Glossario

Arco (edge) Connessione tra due nodi in un grafo $G = (V, E)$. In un grafo non orientato l'arco (u, v) è identico all'arco (v, u); in un grafo orientato (digrafo) i due archi sono distinti e rappresentano relazioni con direzione opposta. In una rete pesata ogni arco porta un valore numerico (il peso w_{ij}) che rappresenta la forza o la capacità della connessione.

Betweenness centrality Misura di centralità di un nodo i che conta quante volte i si trova sul cammino più corto tra ogni coppia di nodi (s, t), normalizzato sul numero totale di cammini più corti tra s e t. Un nodo con alta betweenness funge da *broker* di informazione: controllandolo si può rallentare o bloccare il flusso nella rete. Si estende agli archi (edge betweenness), utile nell'algoritmo di Girvan–Newman per la rilevazione di comunità.

BERT *Bidirectional Encoder Representations from Transformers* (2018). Modello di linguaggio pre-addestrato su grandi corpus testuali che produce rappresentazioni contestuali: la rappresentazione di una parola dipende da tutte le altre parole del contesto sia a sinistra sia a destra. Sentence-BERT (SBERT, 2019) estende BERT per produrre vettori a livello di frase, fondamentali per il topic modeling con BERTopic.

BERTopic Framework di topic modeling non supervisionato (Grootendorst, 2022) che combina quattro passi: embedding dei documenti con Sentence-BERT, riduzione della dimensionalità con UMAP, clustering con HDBSCAN, e rappresentazione dei topic con c-TF-IDF. A differenza di LDA, BERTopic non richiede di specificare a priori il numero di topic e preserva il contesto semantico grazie agli embedding.

BoW (Bag of Words) Rappresentazione di un documento come vettore delle frequenze delle sue parole, ignorando l'ordine e la struttura sintattica. Il vocabolario del corpus definisce la dimensione del vettore; la maggior parte delle componenti è zero (vettore sparso). BoW è semplice e interpretabile ma perde informazione sintattica e semantica, e non distingue usi diversi della stessa parola (omonimia).

Cammino (path) Sequenza di archi adiacenti in un grafo: $(v_0, v_1), (v_1, v_2), \ldots, (v_{k-1}, v_k)$. La *lunghezza* del cammino è il numero di archi (o, in reti pesate, la somma dei pesi). Il cammino più corto tra due nodi è chiamato *cammino geodetico* e la sua lunghezza è la *distanza* tra i nodi.

Cammino euleriano Cammino che attraversa ciascun arco del grafo esattamente una volta. Esiste se e solo se il grafo ha al più due nodi di grado dispari (teorema di Eulero, 1736). Se esiste un cammino euleriano che inizia e finisce nello stesso nodo, si chiama *circuito euleriano* ed esiste se e solo se tutti i nodi hanno grado pari. Il problema dei ponti di Königsberg è l'esempio storico che ha dato origine alla teoria dei grafi.

Camera d'eco (echo chamber) Ambiente informativo in cui un individuo è esposto prevalentemente a contenuti e opinioni che confermano le proprie credenze, a causa di meccanismi di omofilia, algoritmi di raccomandazione personalizzati e autoesclusione dei contenuti dissonanti. Le camere d'eco sono studiate come fattore di polarizzazione dell'opinione pubblica nelle reti sociali digitali.

Centralità Famiglia di misure che quantificano l'importanza di un nodo (o di un arco) all'interno di una rete. Diverse definizioni di "importanza" danno origine a misure diverse: il grado misura il numero di connessioni dirette, la betweenness misura il controllo sui flussi, la closeness misura la rapidità di raggiungimento degli altri, la eigenvector centrality misura l'influenza in base all'importanza dei vicini.

Chiusura triadica Principio per cui se due nodi B e C hanno un amico comune A, esiste una probabilità elevata che B e C formino un legame nel tempo. La chiusura triadica è guidata da opportunità di incontro (attraverso A), fiducia mediata dalla conoscenza comune, e pressione verso la coerenza cognitiva. Il coefficiente di clustering misura il grado in cui la chiusura triadica si è realizzata attorno a un nodo.

Closeness centrality Misura di centralità $C_C(i) = (N-1)/\sum_{j \neq i} d(i,j)$ che quantifica l'inverso della distanza media di un nodo da tutti gli altri. Un nodo con alta closeness è vicino in media a tutti gli altri e può quindi diffondere informazioni rapidamente nell'intera rete. È particolarmente informativa quando si vuole identificare i nodi che minimizzano il tempo di trasmissione globale.

Clustering coefficient Misura della densità locale di un nodo i, definita come il rapporto tra il numero di archi effettivamente presenti tra i vicini di i e il numero massimo possibile: $C_i = 2L_i/[k_i(k_i-1)]$. Vale 0 se nessun vicino è connesso a nessun altro, e 1 se i vicini formano un grafo completo (cricca). Il clustering medio $\langle C \rangle$ è una proprietà globale della rete; reti small-world hanno $\langle C \rangle$ alto con $\langle d \rangle$ basso.

Componente connessa Sottoinsieme massimale di nodi di un grafo non orientato tale che ogni coppia di nodi al suo interno sia collegata da almeno un cammino.

In un grafo orientato si distingue tra componente *fortemente* connessa (ogni nodo raggiunge tutti gli altri seguendo la direzione degli archi) e componente *debolmente* connessa (raggiungibilità ignorando le direzioni). Un grafo con una sola componente connessa è detto *connesso*.

Componente gigante Componente connessa che contiene una frazione significativa (tipicamente $O(N)$) di tutti i nodi di una grande rete. Nei modelli di rete casuale (Erdős–Rényi), la componente gigante emerge per transizione di fase quando il grado medio supera 1: per $\langle k \rangle > 1$ una singola componente domina la rete; per $\langle k \rangle < 1$ la rete è frammentata in piccole componenti. La presenza di una componente gigante è fondamentale per la diffusione di epidemie o informazioni.

c-TF-IDF (class TF-IDF) Variante del TF-IDF usata in BERTopic per rappresentare i topic: tutti i documenti di un cluster vengono concatenati in un unico meta-documento e il peso di un termine t nel cluster c è $f_{t,c}/\sum_{t'} f_{t',c} \times \log(1 + A/f_t)$, dove A è il numero medio di parole per classe. Favorisce termini frequenti nel cluster e rari nel corpus complessivo.

DBSCAN *Density-Based Spatial Clustering of Applications with Noise.* Algoritmo di clustering che individua cluster di forma arbitraria sulla base della densità locale: un punto è un *core point* se almeno `minPts` altri punti cadono entro un raggio ε. I punti non raggiungibili da nessun core point vengono classificati come **rumore**. Non richiede di specificare K a priori ma è sensibile ai parametri ε e `minPts`.

Degree centrality La misura di centralità più semplice: il grado del nodo, ovvero il numero di archi diretti $C_D(i) = k_i$. In reti orientate si distingue tra in-degree (archi entranti, indicatore di popolarità) e out-degree (archi uscenti, indicatore di attività). È facile da calcolare ma può essere fuorviante in reti con distribuzione di grado disomogenea, dove hub e nodi periferici coesistono.

Diametro La massima distanza geodesica tra qualsiasi coppia di nodi in un grafo: $d_{\max} = \max_{u,v} d(u, v)$. In reti disconnesse si calcola separatamente per ogni componente. Il diametro dà un'idea del caso peggiore per la trasmissione di informazioni; nelle reti small-world è sorprendentemente piccolo ($O(\log N)$) nonostante l'enorme numero di nodi.

Digrafo (grafo orientato) Grafo in cui ogni arco ha una direzione: $(u, v) \neq (v, u)$. Esempi: reti di citazioni (un articolo cita un altro, non viceversa), reti follower di Twitter, reti di pagine web collegate da hyperlink. In un digrafo si distin-

guono grado entrante k^{in} e grado uscente k^{out}; la matrice di adiacenza non è necessariamente simmetrica.

Distribuzione di grado La distribuzione di probabilità $p_k = N_k/N$ del grado dei nodi di una rete, dove N_k è il numero di nodi con grado k. Reti casuali (Erdős–Rényi) hanno distribuzione di Poisson; reti reali mostrano spesso code pesanti o distribuzioni a power-law $p_k \sim k^{-\gamma}$ (reti scale-free). La forma della distribuzione di grado determina molte proprietà globali della rete (robustezza, diffusione di epidemie, ecc.).

Eigenvector centrality Misura di centralità in cui l'importanza di un nodo è proporzionale alla somma delle importanze dei suoi vicini: $C_E(i) = (1/\lambda) \sum_{j \in \mathcal{N}(i)} C_E(j)$, equivalente alla soluzione dell'equazione agli autovalori $\mathbf{Ax} = \lambda \mathbf{x}$ con λ massimo. Un nodo guadagna importanza non solo avendo molti vicini ma avendo vicini importanti. PageRank è una variante che aggiunge ammortizzamento (damping) per gestire i dangling nodes.

Embedding Rappresentazione di un oggetto (parola, frase, nodo) come vettore denso in uno spazio $\mathbb{R}^d$ con d relativamente piccolo (tipicamente $d \in [100, 768]$). Negli embedding semantici la distanza vettoriale riflette la similarità di significato: parole usate in contesti simili hanno vettori vicini. Gli embedding consentono operazioni aritmetiche semantiche (es. re–uomo+donna $\approx$ regina) e sono la base di modelli come word2vec, GloVe e BERT.

Eterofilia Tendenza opposta all'omofilia: le connessioni di rete tendono a collegare nodi con attributi diversi più di quanto ci si aspetterebbe dal mixing casuale. Si rileva quando la proporzione osservata di archi eterogenei (che collegano nodi di tipo diverso) è significativamente maggiore del valore atteso $2pq$. Esempi includono reti commerciali (fornitori si connettono a clienti diversi) e alcune reti di conoscenza professionale.

Foci (Feld, 1981) Punti focali di interazione sociale: contesti organizzati (classi scolastiche, luoghi di lavoro, associazioni, eventi) che riuniscono persone con caratteristiche simili e creano opportunità di formazione di legami. Il concetto di Feld spiega come l'omofilia emerga non da una scelta esplicita ma dall'appartenenza a foci omogenei. I foci sono la base delle reti bipartite persona-contesto usate per studiare la *focal closure*.

Grado (degree) Numero di archi incidenti su un nodo. In reti non orientate è uguale al numero di vicini diretti; in reti orientate si distinguono grado entrante k^{in} (archi ricevuti) e grado uscente k^{out} (archi inviati). La somma di tutti i

gradi è il doppio del numero di archi: $\sum_i k_i = 2|E|$. Il grado è la misura di centralità più immediata ma può essere fuorviante in reti molto disomogenee.

Grafo Struttura matematica $G = (V, E)$ composta da un insieme di nodi (vertici) V e un insieme di archi $E \subseteq V \times V$. I grafi sono lo strumento fondamentale per modellare sistemi di entità interconnesse: reti sociali, reti di trasporto, reti biologiche, Internet. La teoria dei grafi, nata con Eulero nel 1736, fornisce il linguaggio formale per analizzare queste strutture.

Grafo bipartito Grafo i cui nodi si dividono in due insiemi disgiunti U e V tali che ogni arco connette un nodo di U a un nodo di V (nessun arco è interno a un insieme). Esempi: persone e film che hanno guardato, utenti e pagine che seguono. La *proiezione* su U crea archi tra nodi di U che condividono almeno un vicino in V, rivelando la struttura di co-partecipazione.

Grafo completo Grafo in cui ogni coppia di nodi distinti è connessa da un arco; il numero di archi è $|E|_{\max} = N(N-1)/2$ per grafi non orientati. In un grafo completo il coefficiente di clustering è 1 per ogni nodo. Le reti reali sono quasi sempre molto lontane dalla completezza (reti sparse).

Grafo connesso Grafo non orientato in cui ogni coppia di nodi è collegata da almeno un cammino, ovvero il grafo ha un'unica componente connessa. Per grafi orientati si parla di *fortemente connesso* (raggiungibilità seguendo le direzioni degli archi) e *debolmente connesso* (raggiungibilità ignorando le direzioni).

Grafo pesato Grafo in cui ogni arco (i, j) ha associato un valore numerico w_{ij} (il peso), che può rappresentare la forza di una relazione (minuti di conversazione, numero di interazioni), la distanza geografica, la capacità di un canale, ecc. Nelle reti pesate le misure di centralità e distanza vengono adattate per tenere conto dei pesi.

HDBSCAN *Hierarchical Density-Based Spatial Clustering of Applications with Noise.* Estensione gerarchica di DBSCAN che non richiede i parametri ε e `minPts` fissi, identifica cluster di densità diversa, e produce una gerarchia di cluster da cui si estrae il partizionamento ottimale. I punti in regioni a bassa densità restano classificati come rumore. In BERTopic viene usato dopo la riduzione dimensionale con UMAP.

Hub Nodo con grado molto superiore alla media in una rete scale-free. La presenza di hub è una conseguenza diretta della distribuzione di grado a power-law: pochi nodi raccolgono un numero enorme di connessioni. Gli hub rendono le reti scale-free robuste a guasti casuali (la probabilità di rimuovere un hub per caso è bassa) ma vulnerabili ad attacchi mirati.

igraph Libreria open-source per l'analisi e la visualizzazione di reti, disponibile per R e Python. Offre funzioni per creare grafi, calcolare misure di centralità, rilevare comunità, tracciare layout e molto altro. È lo strumento principale usato in questo corso per l'analisi pratica delle reti con R.

Influenza sociale Meccanismo per cui i legami esistenti modificano le caratteristiche, i comportamenti e le opinioni degli individui (*peer pressure*). Si distingue dalla *selezione* (formazione di legami con chi è già simile) e co-agisce con essa nel produrre l'omofilia osservata nelle reti sociali. Il disegno longitudinale di studi (Cohen & Kandel) è necessario per separare i due effetti.

K-Means Algoritmo di clustering che partiziona n punti in K cluster minimizzando la varianza intra-cluster. Si scelgono K centroidi iniziali, si assegna ogni punto al centroide più vicino e si ricalcolano i centroidi fino alla convergenza. Limitazioni: richiede K a priori, produce cluster di forma sferica e di dimensioni simili, ed è sensibile agli outlier.

Legame debole / legame forte Dicotomia introdotta da Granovetter (1973) per distinguere relazioni di grande intimità e tempo condiviso (legami forti, tipicamente amici intimi) da relazioni più superficiali (legami deboli, tipicamente conoscenti). I legami deboli tendono a essere ponti locali tra cluster diversi e a portare informazioni nuove non disponibili nel gruppo stretto, da cui la "forza dei legami deboli".

Matrice di adiacenza Rappresentazione matriciale di un grafo di N nodi: la matrice $A \in \{0,1\}^{N\times N}$ ha $A_{ij} = 1$ se esiste un arco da j a i. Per grafi non orientati A è simmetrica. La potenza A^k conta i cammini di lunghezza k tra coppie di nodi, proprietà utile per calcolare misure di centralità spettrali. Lo svantaggio è il costo di memoria $O(N^2)$; per reti sparse si preferisce la lista di adiacenza.

Modularity Misura scalare $Q \in [-0.5, 1]$ che quantifica la qualità di un partizionamento in comunità: confronta la densità di archi all'interno di ciascuna comunità con quella attesa in un grafo casuale con la stessa distribuzione di grado. Valori di $Q > 0.3$ indicano una struttura comunitaria significativa. Molti algoritmi di rilevamento di comunità (es. Louvain) massimizzano Q.

Neighborhood overlap Misura graduale del grado in cui due nodi A e B condividono vicini: $\text{Overlap}(A,B) = |\mathcal{N}(A) \cap \mathcal{N}(B)|/|\mathcal{N}(A) \cup \mathcal{N}(B)|$. Vale 0 quando A e B non hanno vicini in comune (l'arco è un ponte locale), e 1 quando tutti i vicini sono condivisi. Onnela et al. hanno mostrato empiricamente che l'overlap

cresce al crescere della forza del legame, confermando la teoria di Granovetter su scala di milioni di utenti.

Network Science Disciplina accademica interdisciplinare che studia le reti complesse, combinando teoria dei grafi (matematica), meccanica statistica (fisica), data mining (informatica) e struttura sociale (sociologia). Una scoperta centrale è che reti di domini diversi (biologico, tecnologico, sociale) mostrano proprietà strutturali simili (scale-free, small-world) perché governate dagli stessi principi organizzativi (Barabási, 2016).

Nodo (vertex) Elemento base di un grafo, che rappresenta un'entità del sistema modellato: una persona, una pagina web, una proteina, un aeroporto. L'insieme dei nodi è indicato con V; la sua cardinalità $|V| = N$ è la *dimensione* della rete. I nodi possono avere attributi (es. nome, tipo, peso) che arricchiscono l'analisi.

Omofilia Principio per cui le connessioni di una rete tendono a formarsi tra nodi simili per attributi demografici (età, etnia, genere), geografici, culturali o comportamentali. Operazionalmente si misura confrontando la proporzione osservata di archi eterogenei con il valore atteso dal mixing casuale $2pq$. L'omofilia emerge attraverso due meccanismi: selezione (scelta attiva di amici simili) e influenza sociale (convergenza verso i comportamenti degli amici).

Ponte locale Arco (A, B) tale che A e B non hanno nessun amico in comune; la sua rimozione aumenta la distanza $d(A, B)$ a più di 2. I ponti locali sono generalizzazioni dei ponti (la cui rimozione disconnette il grafo): nella pratica i ponti veri sono rarissimi, ma i ponti locali sono comuni e svolgono la stessa funzione di collegamento tra comunità diverse. Secondo la teoria di Granovetter, i legami deboli tendono ad essere ponti locali.

Power-law Distribuzione di probabilità in cui $P(x) \propto x^{-\gamma}$ con $\gamma > 1$. A differenza di una distribuzione gaussiana, non ha una scala caratteristica: eventi molto grandi (nodi di grado altissimo, messaggi virali enormemente condivisi) sono molto più frequenti di quanto previsto dalla distribuzione normale. In Network Science le reti scale-free hanno distribuzioni di grado a power-law con $2 < \gamma < 3$.

Proiezione di rete bipartita Trasformazione di una rete bipartita $G = (U \cup V, E)$ in una rete unimodale su U: si crea un arco tra due nodi di U se hanno almeno un vicino comune in V. La proiezione può essere pesata (il peso dell'arco conta il numero di vicini condivisi). Cattura la struttura di co-partecipazione latente nella rete bipartita originale.

Proprietà STCP (Strong Triadic Closure Property) Proprietà di un nodo A: se A ha legami forti con B e con C, allora esiste almeno un legame (forte

o debole) tra B e C. La violazione di STCP crea tensione cognitiva. Come corollario, se A ha due o più legami forti e un legame che è ponte locale, quest'ultimo deve essere un legame debole: questo è il fondamento formale della "forza dei legami deboli" di Granovetter.

Re-identificazione Processo di associare dati apparentemente anonimi a individui specifici combinando più attributi. Anche quando un dataset viene privato dei dati identificativi diretti (nome, e-mail), la combinazione di attributi indirettamente identificativi (età, residenza, professione, etnia) spesso permette di risalire all'identità. Lo studio di Zimmer (2010) sul dataset Facebook di Harvard è un caso emblematico discusso in questo corso.

Rete bipartita Rete i cui nodi appartengono a due categorie disgiunte U e V, con archi solo tra le due categorie. Modella naturalmente relazioni tra entità di tipo diverso: utenti e prodotti, persone e eventi, autori e articoli. In R, igraph gestisce reti bipartite tramite l'attributo `type` dei nodi e la funzione `bipartite.projection()`.

Rete scale-free Rete con distribuzione di grado a power-law $p_k \sim k^{-\gamma}$. Non ha una scala caratteristica di connettività: la maggior parte dei nodi ha grado basso, ma esistono hub con grado molto elevato. Il meccanismo generativo più noto è l'attaccamento preferenziale di Barabási–Albert (*preferential attachment*): i nuovi nodi si connettono preferibilmente ai nodi già molto connessi ("il ricco diventa più ricco"). Esempi: Internet, reti di citazioni, reti di collaborazione scientifica.

Scale-free Vedi *Rete scale-free*.

Selezione (omofilia) Meccanismo per cui gli individui formano legami preferibilmente con chi è già simile a loro ("birds of a feather flock together"). Agisce principalmente su caratteristiche immutabili (etnia, sesso biologico) e sui valori e interessi preesistenti. È il meccanismo generativo principale dell'omofilia, ma spesso si combina con l'influenza sociale per produrre la correlazione osservata tra attributi degli amici.

Sentimento / Sentiment analysis Analisi automatica della valenza emotiva di un testo (positivo, negativo, neutro) o di emozioni più specifiche (gioia, paura, rabbia, ...). Gli approcci principali includono: dizionari lessicali (AFINN, BING, NRC), classificatori ML supervisionati addestrati su testi annotati, e modelli basati su trasformatori (BERT) che colgono il contesto e la negazione.

Sistema complesso Sistema composto da molte parti interconnesse la cui struttura di connessione è complicata e che presenta *proprietà emergenti*: caratteristiche

del sistema nel suo insieme che non si possono inferire sommando le proprietà dei singoli componenti. Esempi: cervello umano, mercati finanziari, Internet, ecosistemi biologici, reti sociali. La Network Science studia i sistemi complessi attraverso la loro struttura a rete.

Small world Proprietà di una rete che combina lunghezza media del percorso piccola ($\langle d \rangle = O(\log N)$) e alto coefficiente di clustering medio. Cattura l'intuizione dei "sei gradi di separazione": anche in reti enormi chiunque è raggiungibile in pochi passi, eppure i vicini di ciascun nodo tendono a conoscersi tra loro. Il modello di Watts–Strogatz (1998) genera reti con questa proprietà tramite ricablaggio casuale di una piccola frazione degli archi di un anello regolare.

Stopwords Parole grammaticali o molto frequenti (articoli, preposizioni, congiunzioni, ...) che non portano informazione semantica utile per l'analisi testuale e vengono rimosse in fase di preprocessing. Liste standard di stopwords sono disponibili per decine di lingue (es. `stopwords("en")` in quanteda); è comune estenderle con termini specifici del dominio.

Tokenizzazione Processo di suddivisione di un testo in unità minimali (token), tipicamente parole, ma anche sotto-parole, punteggiatura o n-grammi. È il primo passo del preprocessing testuale. Dopo la tokenizzazione si applicano ulteriori operazioni: rimozione delle stopwords, riduzione a minuscolo (*lowercasing*), lemmatizzazione o *stemming* per ricondurre le parole alla loro forma base.

TF-IDF *Term Frequency – Inverse Document Frequency.* Peso assegnato a un termine t in un documento d rispetto a un corpus D: $\mathrm{TF}(t, d) \times \mathrm{IDF}(t, D)$. TF misura quanto spesso il termine appare nel documento (normalizzato per la lunghezza del documento); IDF penalizza i termini che appaiono in molti documenti (termini generici) e premia quelli specifici di pochi documenti. Parole come "il" o "è" hanno IDF ≈ 0 e quindi peso vicino a zero.

Topic modeling Tecnica di apprendimento non supervisionato per scoprire temi latenti in un corpus di testi: dato un insieme di documenti, assegna automaticamente ogni documento a uno o più argomenti (topic), rappresentati come distribuzioni su parole chiave. I modelli classici includono LDA (Latent Dirichlet Allocation); i modelli moderni come BERTopic usano embedding neurali per una migliore cattura del contesto semantico.

UMAP *Uniform Manifold Approximation and Projection.* Algoritmo di riduzione della dimensionalità non lineare che proietta dati da uno spazio ad alta dimensione (es. $\mathbb{R}^{768}$ per BERT) in uno spazio a bassa dimensione (es. $\mathbb{R}^5$)

preservando la struttura locale dei dati. A differenza di PCA (riduzione lineare) o t-SNE (lento su grandi dataset), UMAP scala bene e preserva sia la struttura locale sia quella globale, rendendolo ideale per BERTopic.