Dispensa di

Social Network Analysis

Corso CT0540

Prof.ssa **Fabiana Zollo**

Dipartimento di Scienze Ambientali, Informatica e Statistica
Università Ca' Foscari di Venezia

Anno Accademico 2025–2026

Questa dispensa sintetizza i materiali didattici del corso CT0540 (Social Network Analysis) tenuto presso l'Università Ca' Foscari di Venezia. I contenuti sono tratti dalle slide, dai notebook e dagli script R utilizzati durante le lezioni. Testi di riferimento principali: Easley & Kleinberg, Networks, Crowds, and Markets (Cambridge, 2012); Barabási, Network Science (Cambridge, 2016).

15 aprile 2026

Indice

1 Introduzione alle Reti Sociali **2**
1.1 Il corso CT0540 . . . 2
1.2 Cosa sono le reti sociali? . . . 2
1.3 Tipi di reti . . . 2
1.4 Testi di riferimento . . . 2
1.5 Ricerca e progetti del gruppo . . . 3

2 Teoria dei Grafi **3**
2.1 Il problema dei ponti di Königsberg . . . 3
2.2 Definizioni fondamentali . . . 3
2.3 Grado e distribuzione di grado . . . 4
2.4 Matrice di adiacenza . . . 4
2.5 Reti sparse . . . 4
2.6 Connettività e componenti connesse . . . 5
2.7 Componente gigante (*Giant Component*) . . . 5
2.8 Cammini, distanza e diametro . . . 5
2.9 Il Piccolo Mondo (*Small World*) . . . 6

3 Legami Forti e Deboli **6**
3.1 L'ipotesi di Granovetter . . . 6
3.2 Chiusura Triadica . . . 6
3.3 Coefficiente di Clustering . . . 7
3.4 Ponti e Ponti Locali . . . 7
3.5 La Proprietà di Chiusura Triadica Forte . . . 7
3.6 Dimostrazione formale: ponti locali e legami deboli . . . 7
3.7 Validazione empirica: studio Onnela et al. (reti di telefonia mobile) . 8

4 Contesti Sociali e Omofilia **8**
4.1 Omofilia . . . 8
4.2 Misurare l'Omofilia . . . 9
4.3 Selezione e Influenza Sociale . . . 9
4.4 Affiliazione e Reti Bipartite . . . 10
4.5 Tipi di chiusura nelle reti sociali . . . 10
4.6 Co-evoluzione delle reti sociali e di affiliazione . . . 10

5 Analisi delle Reti con R **11**
5.1 Il pacchetto `igraph` . . . 11
5.2 Costruzione di un grafo . . . 11

5.3 Lettura di dati da file 12
5.4 Visualizzazione avanzata 13

6 Misure di Centralità e Citation Networks 13
6.1 Centralità nelle reti 13
6.2 Centralità di grado (*Degree Centrality*) 14
6.3 Centralità di betweenness 14
6.4 Centralità di vicinanza (*Closeness Centrality*) 14
6.5 Centralità di autovettore (*Eigenvector Centrality*) 14
6.6 Applicazione: Citation Networks con R 14
6.7 Comunità: algoritmo di Girvan–Newman 15

7 Visualizzazione dei Dati 16
7.1 Principi fondamentali 16
7.2 ggplot2 in R 17
7.3 Esempio: Salari dei professori 17
7.4 Buone pratiche 18

8 Filtraggio Dati e Text Analysis 18
8.1 Dataset NYT / COVID-19 18
8.2 Pre-elaborazione del testo con `quanteda` 19
8.3 TF-IDF 19
8.4 Analisi del sentimento 20

9 Topic Modeling con BERTopic 20
9.1 Cos'è il Topic Modeling? 20
9.2 Rappresentazione dei documenti 20
9.3 Il pipeline di BERTopic 21
9.4 Valutazione del modello 22
9.5 Vantaggi e limiti di BERTopic 23
9.6 Varianti di BERTopic 23

10 Big Data e Dati Sociali 23
10.1 Cosa sono i Big Data? 23
10.2 Sei provocazioni sui Big Data (Boyd & Crawford) 24
10.3 Qualità dei dati sociali e tassonomia dei bias (Olteanu et al., 2019) . 26
10.4 Attributi privati nei dati digitali 27

A Formulario riassuntivo 27

B Glossario 27

Capitolo 1. Introduzione alle Reti Sociali

Il corso CT0540

Il corso **CT0540 – Social Network Analysis** introduce lo studio delle reti complesse con un'enfasi sulle reti sociali. Gli argomenti spaziano dalla teoria matematica dei grafi alle applicazioni pratiche con strumenti come R, fino all'analisi del testo e al topic modeling.

Durata: 30 ore di lezioni frontali. Orari: mercoledì 15:45–17:15 (Lab 5) e venerdì 8:45–10:15.

Cosa sono le reti sociali?

Una **rete sociale** è un insieme di attori (individui, organizzazioni, pagine web, ...) e delle relazioni che li connettono. L'analisi di tali reti consente di studiare:

- come scorrono le informazioni attraverso la società;
- i meccanismi di formazione e dissoluzione dei legami;
- le strutture di potere e influenza;
- fenomeni come la diffusione di notizie false (*misinformation*) o di comportamenti.

Tipi di reti

- **Reti di comunicazione**: nodi = dispositivi/persone, archi = canali di comunicazione (es. ARPANET, Internet).
- **Reti di informazione**: nodi = risorse informative (pagine web, articoli), archi = collegamenti logici (hyperlink, citazioni).
- **Reti sociali**: nodi = persone o gruppi, archi = interazioni sociali (amicizia, collaborazione, follower).
- **Reti biologiche**: reti di interazione tra proteine, reti neurali, ecc.

Testi di riferimento

- D. Easley & J. Kleinberg, *Networks, Crowds, and Markets*, Cambridge University Press, 2012. (Bozza pre-pubblicazione liberamente disponibile online.)
- A.-L. Barabási, *Network Science*, Cambridge University Press, 2016.

Ricerca e progetti del gruppo

La Prof.ssa Zollo guida il *Laboratory of Data Science for Society* di Ca' Foscari e coordina diversi progetti europei legati alle reti sociali digitali: IRIS (ecosistemi informativi sani), EUMEPLAT (identità europea nei media), IMSyPP (hate speech), QUEST (comunicazione scientifica).

Capitolo 2. Teoria dei Grafi

Il problema dei ponti di Königsberg

Nel 1735, Königsberg (Prussia Orientale) era attraversata dal fiume Pregel e disponeva di **sette ponti**. Il quesito classico era: è possibile compiere una passeggiata che attraversi ciascun ponte esattamente una volta?

Soluzione di Eulero (1736). Euler modellò il problema con un grafo: quattro nodi (A, B, C, D) corrispondenti ai lembi di terra e sette archi corrispondenti ai ponti. Dimostrò che un cammino euleriano (che attraversa ogni arco una sola volta) *esiste* se e solo se il grafo ha **al più due nodi di grado dispari**. Nel grafo di Königsberg tutti e quattro i nodi hanno grado dispari $\rightarrow$ nessun cammino ammissibile.

L'ottavo ponte (1875). Nel 1875 gli abitanti di Königsberg costruirono un nuovo ponte tra i nodi B e C. Questo ridusse a uno solo il numero di nodi con grado dispari, rendendo possibile trovare il cammino euleriano. L'esempio illustra concretamente come una piccola modifica alla struttura di un grafo possa cambiarne radicalmente le proprietà.

Lezioni chiave:

1. Alcuni problemi diventano più semplici se rappresentati come grafi.
2. I grafi possiedono proprietà intrinseche che limitano o amplificano i comportamenti della rete.

Definizioni fondamentali

Definizione (Grafo). Un grafo $G = (V, E)$ è definito da un insieme di nodi (o vertici) V e un insieme di archi $E \subseteq V \times V$.

Definizione (Grafo non orientato). Gli archi non hanno direzione: $(u, v) \equiv (v, u)$.

Definizione (Grafo orientato (digrafo)). Gli archi hanno una direzione: $(u, v) \neq (v, u)$.

Definizione (Rete pesata). Ogni arco (i, j) ha un peso $w_{ij} \in \mathbb{R}$.

Grado e distribuzione di grado

Il **grado** k_i di un nodo i è il numero di archi che lo collegano ad altri nodi.

Reti non orientate.

$$L = \frac{1}{2}\sum_{i=1}^{N} k_i \qquad \langle k \rangle = \frac{1}{N}\sum_{i=1}^{N} k_i = \frac{2L}{N}$$

Reti orientate. Si distinguono grado entrante k_i^{in} e uscente k_i^{out}:

$$k_i = k_i^{in} + k_i^{out} \qquad \langle k^{in} \rangle = \frac{L}{N} = \langle k^{out} \rangle$$

Distribuzione di grado.

$$p_k = \frac{N_k}{N}$$

dove N_k è il numero di nodi con grado k. Le reti reali spesso mostrano distribuzioni a *power-law* $p_k \sim k^{-\gamma}$ (reti *scale-free*).

Matrice di adiacenza

Per una rete di N nodi, la matrice di adiacenza $A \in \{0,1\}^{N \times N}$ è definita da:

$$A_{ij} = \begin{cases} 1 & \text{se esiste un arco da } j \text{ a } i \\ 0 & \text{altrimenti} \end{cases}$$

Proprietà:

- G non orientato $\Leftrightarrow$ A simmetrica.
- G ha un self-loop $\Leftrightarrow$ $A_{ii} \neq 0$.
- G completo $\Leftrightarrow$ $A_{ij} \neq 0 \ \forall i \neq j$.

Il grado di un nodo si ricava direttamente dalla matrice:

$$k_i = \sum_{j=1}^{N} A_{ji} = \sum_{j=1}^{N} A_{ij} \quad \text{(non orientato)}$$

Reti sparse

Il numero massimo teorico di archi è:

$$|E|_{\max} = \binom{N}{2} = \frac{N(N-1)}{2}$$

Le reti reali sono tipicamente **sparse**: $|E| \ll |E|_{\max}$. Ad esempio, il Karate Club di Zachary: $|V| = 34$, $|E| = 78$, $|E|_{\max} = 561$.

Connettività e componenti connesse

Definizione (Componente connessa). Sottoinsieme massimale di nodi tale che (1) ogni coppia di nodi al suo interno è collegata da almeno un cammino, e (2) non esiste un sottoinsieme più grande con la stessa proprietà.

Un grafo con una sola componente connessa si dice **grafo connesso**; in un grafo disconnesso la matrice di adiacenza può essere riscritta in forma a blocchi diagonali.

Grafi orientati. Per i grafi orientati si distingue tra:

- **Componente fortemente connessa**: ogni nodo raggiunge tutti gli altri *seguendo la direzione degli archi.*
- **Componente debolmente connessa**: ogni coppia di nodi è collegata ignorando la direzione degli archi.

Componente gigante (*Giant Component*)

Nelle reti reali di grandi dimensioni il grafo non è quasi mai completamente connesso, ma esiste tipicamente una sola **componente gigante**: una componente connessa che contiene una frazione significativa di tutti i nodi della rete.

Perché di solito ne esiste solo una? Se esistessero due componenti giganti, sarebbe sufficiente un singolo arco per fonderle in una componente ancora più grande. In reti sociali reali tale arco si forma quasi certamente, quindi le due componenti collassano in una.

Rilevanza pratica. La presenza di una grande componente è cruciale per la diffusione di fenomeni (malattie, informazioni, comportamenti): un individuo con un solo contatto diretto può tuttavia fare parte di una componente che raggiunte la maggioranza della popolazione, percorrendo cammini di trasmissione indiretti.

Lista di adiacenza. Per memorizzare reti di grandi dimensioni (sparse) è conveniente usare una **lista di adiacenza** anziché la matrice di adiacenza completa: si memorizzano solo gli archi esistenti, riducendo il costo di memoria da $O(N^2)$ a $O(N + L)$.

Cammini, distanza e diametro

Definizione (Cammino). Sequenza di archi $(v_0, v_1), (v_1, v_2), \ldots, (v_{k-1}, v_k)$.

Definizione (Distanza geodesica). $d(u, v)$ è la lunghezza del cammino più breve tra u e v.

Definizione (Diametro). Il diametro di una rete è $d_{\max} = \max_{u,v} d(u, v)$, ovvero la massima distanza geodesica registrata tra qualsiasi coppia di nodi.

Definizione (Lunghezza media del percorso). $\langle d \rangle = \frac{1}{N(N-1)} \sum_{i \neq j} d(i,j)$ è la distanza media tra tutte le coppie di nodi (calcolata solo all'interno della stessa componente connessa).

Il Piccolo Mondo (*Small World*)

L'esperimento di Milgram (1967) suggerì che la distanza media tra due individui negli USA fosse circa **sei gradi di separazione**. Un'analisi successiva su Microsoft Messenger (circa 240 milioni di utenti) stimò una lunghezza media del percorso $\langle d \rangle \approx 6.6$ e una mediana di 7. Le reti reali mostrano tipicamente:

1. $\langle d \rangle$ **piccola**: la lunghezza media del percorso cresce come $\log N$, molto più lentamente della dimensione della rete.
2. **Alto coefficiente di clustering**: i vicini di un nodo tendono ad essere connessi tra loro (molto di più di quanto ci si aspetterebbe in un grafo casuale).

La coesistenza di questi due fenomeni è catturata dal **modello di Watts–Strogatz (1998)**: partendo da un grafo ad anello regolare, il ricablaggio casuale di una piccola frazione di archi abbassa drasticamente $\langle d \rangle$ mantenendo alto il clustering.

Capitolo 3. Legami Forti e Deboli

L'ipotesi di Granovetter

Negli anni '60, il sociologo Mark Granovetter condusse interviste con persone che avevano cambiato lavoro. Scoprì che molti avevano appreso dell'opportunità tramite **conoscenti**, non amici intimi.

Granovetter formulò l'ipotesi della **"forza dei legami deboli"**: i legami deboli (con conoscenti distanti) fungono da *ponti* tra porzioni diverse della rete, trasmettendo informazioni nuove non disponibili nel proprio gruppo stretto.

Chiusura Triadica

Definizione (Chiusura triadica). Se A è amico di B e di C, allora esiste una probabilità elevata che B e C diventino amici nel tempo.

Ragioni della chiusura triadica:

1. **Opportunità**: B e C si incontrano attraverso A.
2. **Fiducia**: la conoscenza comune A funge da garante.
3. **Incentivo**: la tensione cognitiva spinge verso equilibrio.

Coefficiente di Clustering

Il **coefficiente di clustering locale** di un nodo i con grado k_i è:

$$C_i = \frac{2L_i}{k_i(k_i - 1)}$$

dove L_i è il numero di archi tra i vicini di i.

$C_i = 0$: nessuno dei vicini è connesso tra loro. $C_i = 1$: tutti i vicini formano un grafo completo.

Il **coefficiente di clustering medio** di una rete è:

$$\langle C \rangle = \frac{1}{N} \sum_{i=1}^{N} C_i$$

Ponti e Ponti Locali

Definizione (Ponte). Un arco (A, B) è un ponte se la sua rimozione disconnette A e B (li porta in componenti distinte).

Definizione (Ponte locale). Un arco (A, B) è un ponte locale se A e B non hanno nessun amico in comune. La sua rimozione aumenta la distanza $d(A, B) > 2$.

Relazione con la chiusura triadica: un arco è un ponte locale precisamente quando non forma il lato di nessun triangolo. Ponti locali e chiusura triadica sono concetti opposti.

La Proprietà di Chiusura Triadica Forte

Categorizzando i legami in **forti** (amici intimi) e **deboli** (conoscenti):

Proprietà STCP. Se un nodo A ha legami forti con B e C, allora esiste un legame (almeno debole) tra B e C.

Conseguenza. I legami deboli sono candidati naturali a essere ponti locali: se A–B fosse forte e fosse un ponte locale, violerebbero STCP. Questo spiega perché i legami deboli portano informazioni nuove.

Dimostrazione formale: ponti locali e legami deboli

Claim. Se un nodo A soddisfa la STCP ed è coinvolto in almeno due legami forti, allora qualsiasi ponte locale a cui A partecipa deve essere un legame debole.

Dimostrazione (per assurdo).

1. Supponiamo che A abbia un legame forte con B e che A–B sia un ponte locale.

2. Poiché A ha almeno due legami forti, esiste un altro nodo C con A–C forte.
3. Poiché A–B è un ponte locale, A e B non hanno amici in comune → B e C non sono connessi.
4. Ma A–B forte e A–C forte con B–C assente viola la STCP. Contraddizione. □

Quindi **i legami deboli hanno un duplice ruolo**: sono connessioni superficiali (bassa forza) ma al tempo stesso preziosi ponti verso parti distanti della rete ("la forza dei legami deboli" di Granovetter).

Validazione empirica: studio Onnela et al. (reti di telefonia mobile)

Per molti anni le previsioni di Granovetter rimasero difficili da verificare su larga scala. Con l'avvento delle comunicazioni digitali, Onnela et al. studiarono la rete *chi-chiama-chi* di un operatore di telefonia mobile, con milioni di nodi.

Misura continua della forza del legame. Nelle reti reali la dicotomia forte/debole è troppo rigida. La forza di un arco A–B viene definita come il tempo totale di conversazione tra A e B; si può poi ordinare tutti gli archi per percentile di forza.

Neighborhood overlap. Analogamente, la proprietà di "ponte locale" (nessun amico in comune) è rarissima nelle reti reali. Si introduce quindi una misura graduale:

$$\text{Neighborhood Overlap}(A, B) = \frac{|\mathcal{N}(A) \cap \mathcal{N}(B)|}{|\mathcal{N}(A) \cup \mathcal{N}(B)|}$$

dove $\mathcal{N}(X)$ è l'insieme dei vicini di X (escluso il nodo stesso).

- Overlap = 0: A e B non hanno vicini in comune → arco è un ponte locale.
- Overlap piccolo: arco è "quasi" un ponte locale.
- Overlap grande: arco è immerso in un gruppo fitto.

Risultato. Lo studio di Onnela et al. confermò la previsione di Granovetter: all'aumentare della forza del legame, l'overlap di vicinato cresce sistematicamente. In altre parole, i legami deboli tendono ad avere overlap basso e a fungere da ponti tra comunità distinte, mentre i legami forti collegano nodi con molti amici in comune.

Capitolo 4. Contesti Sociali e Omofilia

Omofilia

Definizione (Omofilia). Il principio per cui tendiamo ad essere simili ai nostri amici.

I legami nelle reti sociali tendono a connettere persone simili per età, etnia, luogo di residenza, occupazione, interessi e opinioni. L'omofilia può guidare la formazione di legami e rafforzare la chiusura triadica: se A–B e A–C sono amici, l'omofilia suggerisce che B e C siano già simili tra loro, aumentando la probabilità di un legame B–C.

Misurare l'Omofilia

Dato un attributo categorico (es. genere) con frazione p di nodi tipo "maschio" e frazione $q = 1 - p$ di nodi tipo "femmina":

Se i legami fossero formati casualmente, la frazione attesa di archi *eterogenei* (che collegano i due tipi) sarebbe:

$$2pq$$

Se la frazione osservata di archi eterogenei è *minore* di $2pq$, la rete mostra **omofilia**; se è *maggiore*, mostra **eterofilia**.

Esempio numerico. Consideriamo una rete scolastica con 9 alunni: 6 maschi ($p = 6/9 = 2/3$) e 3 femmine ($q = 3/9 = 1/3$). La rete ha 18 archi totali, di cui 5 sono eterogeni (collegano un maschio a una femmina). Con il mixing casuale ci aspetteremmo $2pq = 2 \cdot (2/3) \cdot (1/3) = 4/9$ di archi eterogeni, ovvero $18 \times (4/9) = 8$ archi. Ne osserviamo solo $5 < 8 \rightarrow$ **evidenza di omofilia per genere**.

Note metodologiche.

1. Il numero atteso $2pq \cdot |E|$ varia per effetto del campionamento; per concludere all'omofilia occorre verificare che lo scarto sia *statisticamente significativo* (es. con un test del chi-quadro o mediante permutazioni).

2. Se la frazione di archi eterogenei è significativamente *maggiore* di $2pq$, si parla di **eterofilia** (o omofilia inversa): le persone tendono a legarsi con chi è diverso da loro.

3. Il test si estende a caratteristiche con più di due valori: un arco è *eterogeneo* se i suoi estremi hanno valori diversi, e si calcola la proporzione di archi eterogenei attesa dal mixing casuale sulla base della distribuzione dei valori nella rete.

Selezione e Influenza Sociale

Due meccanismi generano l'omofilia osservata:

- **Selezione**: le persone formano legami con chi è già simile a loro (*"birds of a feather flock together"*).

- **Influenza sociale**: i legami esistenti modificano i comportamenti e le caratteristiche degli individui (*peer pressure*).

Caratteristiche immutabili (sesso biologico, etnia): solo la selezione opera.
Caratteristiche mutabili (comportamenti, opinioni, interessi): entrambi i meccanismi operano.

Esempio. Studi longitudinali sugli adolescenti (Cohen & Kandel) mostrano che sia selezione sia influenza sociale spiegano la somiglianza comportamentale tra amici, con l'influenza sociale più moderata della selezione. Capire quale meccanismo prevalga è fondamentale per progettare interventi efficaci (es. programmi anti-droga).

Affiliazione e Reti Bipartite

Possiamo modellare reti che includono sia **persone** sia **contesti** (focus group, club, classi, eventi) come nodi, connettendo persone ai contesti in cui partecipano. Feld (1981) chiama questi contesti **foci**: punti focali di interazione sociale. Si ottiene una **rete bipartita**: due tipi di nodi (persone e foci), archi solo tra tipi diversi.

La **proiezione** su un tipo di nodi crea archi tra persone che condividono un contesto, spiegando così l'emergere dell'omofilia anche senza scelta esplicita di amici simili.

Tipi di chiusura nelle reti sociali

Nelle reti sociali si distinguono tre forme di chiusura che guidano la formazione di nuovi legami:

- **Chiusura triadica**: B e C diventano amici perché hanno un amico comune A (entrambi sono persone).
- **Chiusura focale** (*focal closure*): B e C diventano amici perché partecipano a un focus comune A (es. stessa classe, stessa associazione).
- **Chiusura di membership** (*membership closure*): B aderisce a un focus a cui il suo amico A già partecipa (forma di influenza sociale sui foci scelti).

Co-evoluzione delle reti sociali e di affiliazione

Le reti sociali e le reti di affiliazione **co-evolvono**: la partecipazione a un focus crea opportunità di amicizia; le amicizie esistenti influenzano la scelta dei foci futuri. Questo meccanismo spiega perché l'omofilia osservata nelle reti sociali emerga in parte spontaneamente, anche in assenza di una scelta deliberata di amici simili.

Studio empirico: Kossinets & Watts. Kossinets e Watts analizzarono una rete di e-mail universitaria seguita nel tempo, integrando i dati di comunicazione con gli orari delle lezioni (ogni corso = un focus). Misurarono la probabilità giornaliera di formazione di un legame in funzione di:

- il numero di amici in comune (chiusura triadica): la probabilità cresce in modo superlineare con il numero di amici condivisi.
- il numero di corsi condivisi (chiusura focale): un singolo corso condiviso ha un effetto assoluto simile a un singolo amico in comune, ma l'effetto si satura rapidamente all'aggiunta di ulteriori corsi condivisi.

Il confronto mostra che chiusura triadica e focale sono meccanismi complementari e paragonabili per importanza nella formazione di legami.

Capitolo 5. Analisi delle Reti con R

Il pacchetto `igraph`

La libreria **igraph** (disponibile per R e Python) è lo strumento standard per l'analisi e la visualizzazione di reti. Si installa con:

```
install.packages("igraph")
library(igraph)
```

Costruzione di un grafo

```
# Grafo diretto vuoto
g <- graph.empty(directed = TRUE)

# Aggiunta di nodi (famiglia reale)
g <- g + vertex("Elizabeth II")
g <- g + vertex("Philip")
g <- g + vertex("Charles")
g <- g + vertex("Diana")
g <- g + vertex("William")
g <- g + vertex("Harry")
g <- g + vertex("Catherine")
g <- g + vertex("George")

# Aggiunta di archi (relazioni genitore -> figlio)
g <- g + edges("Elizabeth II", "Charles")
g <- g + edges("Philip",       "Charles")
```

```
g <- g + edges("Charles",      "William")
g <- g + edges("Diana",        "William")
g <- g + edges("Charles",      "Harry")
g <- g + edges("Diana",        "Harry")
g <- g + edges("William",      "George")
g <- g + edges("Catherine",    "George")

plot.igraph(g)
```

```
# Grafo da lista di archi
g1 <- graph(edges = c(1,2, 2,3, 3,1), n = 3, directed =
   FALSE)
plot(g1)

# Grafo con nomi
g3 <- graph(c("John","Jim","Jim","Jill","Jill","John"))
plot(g3)

# Grafo da formula letterale
plot(graph_from_literal(a---b, b---c))  # non orientato
plot(graph_from_literal(a--+b, b+--c)) # orientato
```

Lettura di dati da file

```
# Dataset 1: rete media (orientata, lista di archi)
nodes <- read.csv("Dataset1-Media-Example-NODES.csv",
                  header = TRUE, as.is = TRUE)
links <- read.csv("Dataset1-Media-Example-EDGES.csv",
                  header = TRUE, as.is = TRUE)
net <- graph_from_data_frame(d = links, vertices = nodes,
                             directed = TRUE)
plot(net, edge.arrow.size = 0.4, edge.curved = 0.1)
```

```
# Dataset 2: rete bipartita (matrice di incidenza)
nodes2 <- read.csv("Dataset2-Media-User-Example-NODES.csv
   ",
                   header = TRUE, as.is = TRUE)
links2 <- read.csv("Dataset2-Media-User-Example-EDGES.csv
   ",
                   header = TRUE, row.names = 1)
links2 <- as.matrix(links2)
```

```
net2   <- graph_from_incidence_matrix(links2)
table(V(net2)$type)  # numero nodi per tipo
plot(net2, vertex.label = NA)
```

Visualizzazione avanzata

```
# Colori per tipo di medium
colrs <- c("gray50", "tomato", "gold")
V(net)$color <- colrs[V(net)$media.type]

# Dimensione nodi proporzionale al grado
V(net)$size <- degree(net) * 2

# Stile degli archi
E(net)$width  <- E(net)$weight / 5
E(net)$arrow.size <- 0.3

plot(net,
     vertex.label = V(net)$media,
     vertex.label.color = "black",
     vertex.label.cex = 0.7,
     layout = layout_with_fr(net))
```

```
# Rete bipartita con proiezioni
net2.bp <- bipartite.projection(net2)
plot(net2.bp$proj1,
     vertex.label.color = "black",
     vertex.label.dist  = 1,
     vertex.label = nodes2$media[!is.na(nodes2$media.type)
        ])

# Layout bipartito esplicito
plot(net2, vertex.label = NA, vertex.size = 7,
     layout = layout_as_bipartite)
```

Capitolo 6. Misure di Centralità e Citation Networks

Centralità nelle reti

La **centralità** misura l'importanza di un nodo nella rete. Esistono diverse misure, ognuna con un'interpretazione diversa di "importanza".

Centralità di grado (*Degree Centrality*)

Il nodo più connesso è quello con il grado massimo:

$$C_D(i) = k_i$$

Centralità di betweenness

La **betweenness centrality** misura quante volte un nodo si trova sui cammini più corti tra coppie di nodi:

$$C_B(i) = \sum_{s \neq i \neq t} \frac{\sigma_{st}(i)}{\sigma_{st}}$$

dove σ_{st} è il numero di cammini più corti tra s e t, e $\sigma_{st}(i)$ quanti di essi passano per i.

I nodi con alta betweenness sono **broker** di informazione.

Centralità di vicinanza (*Closeness Centrality*)

$$C_C(i) = \frac{N-1}{\sum_{j \neq i} d(i,j)}$$

Un nodo con alta closeness raggiunge rapidamente tutti gli altri.

Centralità di autovettore (*Eigenvector Centrality*)

La centralità di autovettore assegna importanza a un nodo in base all'importanza dei suoi vicini:

$$C_E(i) = \frac{1}{\lambda} \sum_{j \in \mathcal{N}(i)} C_E(j)$$

In notazione matriciale: $\mathbf{A}\,\mathbf{x} = \lambda\,\mathbf{x}$ dove $\mathbf{x}$ è l'autovettore associato all'autovalore massimo. PageRank di Google è una variante.

Applicazione: Citation Networks con R

```r
library(igraph)

# Caricamento dati
allCounts <- as.matrix(read.csv("ac.csv", as.is = TRUE))
G <- graph.edgelist(allCounts, directed = FALSE)

# Sottografo su specifici temi
themes <- read.csv("themes.csv", as.is = TRUE)
matchingCases    <- which(themes$issue %in% c(20040,
   20050))
```

```r
matchingCases_ids <- themes$usid[matchingCases]
H <- induced.subgraph(G, matchingCases_ids)

# Layout di Fruchterman-Reingold
set.seed(1)
lout <- layout.fruchterman.reingold(H)
plot.igraph(H, layout = lout, vertex.size = 5,
            vertex.label.cex = 0.5)
```

```r
# Eigenvector Centrality
eigenCent <- evcent(H)$vector
sort(eigenCent, decreasing = TRUE)[1:10]

# Colorazione heat map per centralita'
bins     <- unique(quantile(eigenCent, seq(0, 1, length.out = 30)))
vals     <- cut(eigenCent, bins, labels = FALSE, include.lowest = TRUE)
colorVals <- rev(heat.colors(length(bins)))[vals]
V(H)$color <- colorVals
plot.igraph(H, vertex.label = NA, vertex.size = 5)

# Betweenness Centrality
betweenCent <- betweenness(H)
sort(betweenCent, decreasing = TRUE)[1:10]
cor(betweenCent, eigenCent)   # correlazione tra le due misure
```

Comunità: algoritmo di Girvan–Newman

Partizionamento dei grafi. L'obiettivo è suddividere un grafo in **regioni dense** (comunità) con connessioni sparse tra di esse. Esistono due famiglie principali di metodi:

- **Metodi divisivi** (top-down): identificano e rimuovono gli archi di collegamento tra comunità, a partire dall'intero grafo.
- **Metodi agglomerativi** (bottom-up): partono dai singoli nodi e li uniscono progressivamente nelle stesse comunità sulla base di criteri di similarità.

Betweenness degli archi (*Edge Betweenness*). Per selezionare quale arco rimuovere nei metodi divisivi si usa la **betweenness degli archi**: la quantità totale

di flusso che passa per quell'arco. Formalmente, si suppone che per ogni coppia di nodi (s, t) esista un'unità di flusso che si distribuisce equamente sui cammini più corti da s a t; la betweenness dell'arco (u, v) è la somma di questi flussi su tutte le coppie.

$$C_B(u, v) = \sum_{s \neq t} \frac{\sigma_{st}(u, v)}{\sigma_{st}}$$

Gli archi con alta betweenness sono "ponti" tra comunità; i nodi con alta betweenness (node betweenness) **occupano buchi strutturali** (*structural holes*) e fungono da intermediari di informazione.

Il metodo di Girvan–Newman è un metodo divisivo basato sulla betweenness degli archi:

1. Calcola la betweenness di tutti gli archi.
2. Rimuove l'arco (o gli archi) con betweenness massima.
3. Ricalcola la betweenness di tutti gli archi rimasti (la rimozione altera i cammini più corti).
4. Ripete finché non rimangono archi.

Il metodo è efficace su reti di dimensioni moderate (qualche migliaio di nodi); per reti più grandi il ricalcolo iterativo della betweenness diventa computazionalmente costoso, rendendo preferibili metodi agglomerativi o approssimazioni.

```r
# Rilevamento comunita' tramite edge betweenness
w <- edge.betweenness.community(H)
sort(table(w$membership))    # distribuzione delle comunita'
```

Capitolo 7. Visualizzazione dei Dati

Principi fondamentali

Una buona visualizzazione deve:

1. Mostrare i dati veritieramente, senza distorsioni.
2. Facilitare il confronto.
3. Essere comprensibile al pubblico di riferimento.
4. Scegliere il tipo di grafico adatto al tipo di dato.

ggplot2 in R

ggplot2 implementa la *Grammar of Graphics*: ogni visualizzazione si compone di dati, mapping estetici (*aesthetics*) e oggetti geometrici (*geom*).

```r
library(ggplot2)

# Scatterplot base
ggplot(data = mpg) +
  geom_point(mapping = aes(x = displ, y = hwy))

# Colore per classe
ggplot(data = mpg) +
  geom_point(mapping = aes(x = displ, y = hwy, color =
     class))

# Dimensione per classe
ggplot(data = mpg) +
  geom_point(mapping = aes(x = displ, y = hwy, size =
     class))

# Facets (griglia di grafici per sotto-gruppi)
ggplot(data = mpg) +
  geom_point(mapping = aes(x = displ, y = hwy)) +
  facet_wrap(~ class)
```

```r
# Curva smoothing
ggplot(data = mpg) +
  geom_smooth(mapping = aes(x = displ, y = hwy))

# Linee differenti per tipo di trazione
ggplot(data = mpg) +
  geom_smooth(mapping = aes(x = displ, y = hwy, linetype =
      drv))

# Combinare piu' geom
ggplot(data = mpg) +
  geom_point(mapping  = aes(x = displ, y = hwy)) +
  geom_smooth(mapping = aes(x = displ, y = hwy))
```

Esempio: Salari dei professori

```r
library(car)
data(Salaries)

# Correlazione tra stipendio e anni dal PhD
with(Salaries, cor(salary, yrs.since.phd))   # ~0.42
with(Salaries, cor(salary, yrs.service))     # ~0.33

# Test di correlazione
with(Salaries, cor.test(salary, yrs.since.phd))
```

Buone pratiche

- Evitare grafici a torta per più di 4-5 categorie (preferire barplot).
- Non troncare l'asse Y (a meno che non sia esplicitamente giustificato).
- Usare colori accessibili (palette friendly per daltonici).
- Includere sempre assi etichettati, titolo e fonte dei dati.
- Scegliere la scala appropriata (lineare vs. logaritmica).

Capitolo 8. Filtraggio Dati e Text Analysis

Dataset NYT / COVID-19

L'analisi testuale del corso utilizza un corpus di post Facebook del *New York Times* relativi alla pandemia COVID-19. Il workflow di preprocessing è il seguente.

```r
posts <- read.csv("nyt_posts.csv")
posts <- posts[, -(37:40)]    # rimozione colonne inutili
dim(posts)

# Filtraggio per engagement minimo
p <- posts[posts$Likes > 4 & posts$Comments > 4 &
   posts$Shares > 4, ]
paste0(round(dim(p)[1] / dim(posts)[1], 2) * 100, "%")

# Estrazione ID post dall'URL
library(stringr)
p$post_id <- str_sub(p$URL, 43, 60)
table(p$Type)
```

```r
# Selezione post con "COVID-19" nel testo
m <- as.character(df_other$text)
y <- which(unlist(lapply(m, function(x) {
       grepl("COVID-19", x, ignore.case = TRUE)
     })))
posts_covid_m <- df_other[y, ]
```

Pre-elaborazione del testo con quanteda

```r
library(quanteda)
source("stopwords_extended.R")

# Costruzione del corpus
corpus <- corpus(posts_covid_lm, text_field = "text")

# Tokenizzazione e pulizia
doc.tokens <- tokens(corpus)
doc.tokens <- tokens(doc.tokens,
                     remove_punct   = TRUE,
                     remove_numbers = TRUE)
doc.tokens <- tokens_select(doc.tokens,
                 stopwords(language = "en", source = "
                    snowball"),
                 selection = "remove")
doc.tokens <- tokens_select(doc.tokens, stopmore,
                            selection = "remove")
doc.tokens <- tokens_tolower(doc.tokens)
toks_ngram  <- tokens_ngrams(doc.tokens, n = 1:2)

# Document-Feature Matrix (DFM)
dfmat1 <- dfm(toks_ngram) |> dfm_trim(min_termfreq = 10)
dfmat1
```

TF-IDF

Il peso **TF-IDF** (*Term Frequency – Inverse Document Frequency*) misura l'importanza di un termine t in un documento d rispetto a un corpus D:

$$\mathrm{TF}(t,d) = \frac{f_{t,d}}{\sum_{t'} f_{t',d}} \qquad \mathrm{IDF}(t,D) = \log \frac{|D|}{|\{d \in D : t \in d\}|}$$

$$\text{TF-IDF}(t, d, D) = \text{TF}(t, d) \times \text{IDF}(t, D)$$

Termini molto frequenti in tutto il corpus (es. "the", "a") ricevono IDF basso e quindi peso basso, mentre termini specifici di pochi documenti ricevono peso alto.

```r
library(quanteda.textstats)

# 100 termini piu' frequenti
features_dfm <- textstat_frequency(dfmat1, n = 100)

# TF-IDF
dfmat_tfidf <- dfm_tfidf(dfmat1)
```

Analisi del sentimento

L'analisi del sentimento assegna a testi un punteggio di valenza emotiva (positivo, negativo, neutro). Approcci principali:

- **Dizionari lessicali** (es. AFINN, BING, NRC): lookup diretto.
- **Modelli ML supervisionati**: classificatori addestrati su testi annotati.
- **Modelli basati su trasformatori** (BERT): catturano il contesto.

Capitolo 9. Topic Modeling con BERTopic

Cos'è il Topic Modeling?

Il **topic modeling** è una tecnica di apprendimento non supervisionato per scoprire temi latenti in un corpus di testi. Dato un insieme di documenti (tweet, articoli, commenti, ecc.), l'obiettivo è assegnare automaticamente ogni documento a uno o più argomenti.

Rappresentazione dei documenti

Bag of Words (BoW). Ogni documento è rappresentato dalla frequenza delle sue parole (vettore sparso).

✓ Semplice, interpretabile.

× Perde informazione sintattica e semantica; problemi con omonimia ed enantiosemia.

Embeddings (word2vec, BERT). Ogni parola/frase viene mappata in un vettore denso nello spazio $\mathbb{R}^d$ dove la similarità vettoriale riflette la similarità semantica.

Il modello **BERT** (*Bidirectional Encoder Representations from Transformers*, 2018) legge il testo in entrambe le direzioni e produce rappresentazioni contestuali. **Sentence-BERT** (SBERT, 2019) usa il *mean pooling* sulle rappresentazioni per ottenere un embedding a livello di frase.

- ✓ Nessun preprocessing testuale specifico; mantiene il contesto.
- × Non interpretabile; limite di lunghezza ($\sim$500 token $\approx$ 300 parole); può risentire di bias nel corpus di addestramento.

La maledizione della dimensionalità (*Curse of Dimensionality*). Dopo l'embedding, ogni documento è un punto in uno spazio con centinaia di dimensioni ($d \approx 768$ per BERT). In spazi ad altissima dimensione il concetto di "distanza" perde significato: quasi tutte le coppie di punti diventano equidistanti, rendendo il clustering inefficace. Per questo BERTopic introduce un passo di **riduzione della dimensionalità** prima del clustering.

Il pipeline di BERTopic

BERTopic (Grootendorst, 2022) combina quattro passi:

1. **Embedding dei documenti** tramite SBERT: ogni documento diventa un vettore in uno spazio ad alta dimensione ($d \approx 768$).
2. **Riduzione della dimensionalità** con UMAP: da $\mathbb{R}^{768}$ a $\mathbb{R}^5$ (o meno), preservando la struttura locale.
3. **Clustering** con HDBSCAN: raggruppa documenti semanticamente simili in cluster; i documenti fuori da tutti i cluster sono etichettati come "rumore".
4. **Rappresentazione dei topic** con c-TF-IDF: per ogni cluster si calcola un TF-IDF "classico" applicato ai cluster come fossero documenti.

UMAP (Uniform Manifold Approximation and Projection). UMAP riduce la dimensionalità preservando la struttura locale dei dati:

1. Costruisce un grafo di vicinanza nello spazio ad alta dimensione.
2. Costruisce un grafo equivalente in bassa dimensione.
3. Minimizza la *cross-entropy loss* tra i due grafi tramite discesa del gradiente stocastica.

Il risultato è una proiezione che preserva i cluster semantici. La qualità dipende dal parametro K (numero di vicini considerati).

Algoritmi di clustering: da K-Means a HDBSCAN. **K-Means** è l'algoritmo di clustering più semplice: si scelgono K centroidi, si assegna ogni punto al centroide più vicino, si ricalcolano i centroidi, e si ripete fino alla convergenza. Limitazione principale: richiede di specificare K a priori e produce cluster di forma sferica.

DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) supera questi limiti: individua cluster di forma arbitraria sulla base della densità locale (parametri: raggio ε e numero minimo di punti `minPts`), e classifica i punti isolati come **rumore**. Complessità media $O(n \log n)$.

HDBSCAN (*Hierarchical DBSCAN*) estende DBSCAN:

- non richiede di specificare il numero di cluster *a priori*;
- individua cluster di forma arbitraria e con densità diverse;
- richiede un solo iperparametro principale (dimensione minima del cluster);
- etichetta come rumore i punti in regioni a bassa densità.

c-TF-IDF (class-TF-IDF). Per ottenere le parole rappresentative di ogni topic, BERTopic unisce tutti i documenti di un cluster in un unico "meta-documento" e calcola:

$$c\text{-TF-IDF}_{t,c} = \frac{f_{t,c}}{\sum_{t'} f_{t',c}} \times \log\left(1 + \frac{A}{f_t}\right)$$

dove $f_{t,c}$ è la frequenza di t nel cluster c, f_t è la frequenza totale di t nel corpus, e A è il numero medio di parole per classe.

Altre rappresentazioni dei topic. BERTopic supporta rappresentazioni alternative alla c-TF-IDF:

- **Marginal Maximum Relevance (MMR)**: bilancia rilevanza e diversità delle parole chiave.
- **Part of Speech (POS)**: filtra le parole chiave per categoria grammaticale.
- **KeyBERT**: usa gli embedding BERT per trovare le parole più simili semanticamente al topic.
- **LLM**: sfrutta modelli di linguaggio di grandi dimensioni per generare etichette o riassunti testuali per ciascun topic.

Valutazione del modello

BERTopic richiede la scelta di diversi iperparametri (embedding model, numero di vicini UMAP, dimensione minima del cluster HDBSCAN, lingua per le stopword). La valutazione avviene sia quantitativamente sia qualitativamente.

Metriche quantitative:

- **DB Cluster Relative Validity (DBCV)**: misura la qualità del clustering tra -1 e 1; valori più alti indicano cluster più coesi e separati. Permette di confrontare diversi run con parametri diversi sullo stesso corpus.
- **Coherence score**: misura la coerenza semantica dei topic, valutando quanto spesso le parole chiave di un topic co-occorrono nel corpus.
- **Diversity score** (es. Jaccard Topic Diversity): misura quanto i topic siano distinti tra loro calcolando la proporzione di parole chiave uniche sul totale.

Ispezione manuale: la lettura delle parole chiave e dei documenti rappresentativi di ciascun topic rimane il metodo più affidabile ma richiede molto tempo.

Vantaggi e limiti di BERTopic

Vantaggi	Limiti
Scalabile a grandi corpus	Richiede GPU per l'embedding
Preserva il contesto semantico	Molti iperparametri da ottimizzare
Flessibile (componenti sostituibili)	Limite di lunghezza dei documenti
Topic interpretabili tramite parole chiave	Possibili bias dal corpus di pre-addestramento

Varianti di BERTopic

- **Dynamic Topic Modeling**: evoluzione dei topic nel tempo.
- **Guided Topic Modeling**: incorporazione di seed words.
- **Zero-shot Topic Modeling**: classificazione senza dati di addestramento.
- **Online Topic Modeling**: aggiornamento incrementale del modello.

Capitolo 10. Big Data e Dati Sociali

Cosa sono i Big Data?

"*Big Data*" è un termine spesso frainteso: non si riferisce semplicemente a grandi quantità di dati, ma a una **capacità di ricerca, aggregazione e incrocio** di insiemi di dati eterogenei [**?**, Boyd & Crawford, 2012].

Due interpretazioni prevalenti:

1. **Strumento potente**: permette di affrontare questioni sociali complesse su larga scala.

2. **Manifestazione preoccupante**: rischi per la privacy, la libertà civile e il controllo governativo/corporativo.

Le **quattro forze regolatrici** dei sistemi sociali (Lessig, 1999):

- **Mercato**: i Big Data rappresentano un'opportunità commerciale enorme.
- **Legge**: i Big Data sollevano preoccupazioni sulla privacy e la protezione dei dati personali (es. GDPR).
- **Norme sociali**: la personalizzazione algoritmica è vista come utile (informazioni più rilevanti) ma anche come fonte di frammentazione del dibattito pubblico (camere d'eco).
- **Architettura (codice)**: le piattaforme digitali progettano ambienti che modellano i comportamenti degli utenti, spesso in modo opaco.

Queste forze sono spesso in conflitto nell'ecosistema dei Big Data.

Sei provocazioni sui Big Data (Boyd & Crawford)

1. I Big Data cambiano la definizione di conoscenza. L'emergere di sistemi computazionali per l'analisi dei dati modifica il modo in cui costruiamo conoscenza scientifica e sociale. I tool disponibili hanno limitazioni strutturali (es. archivi Twitter/Facebook di difficile accesso) che condizionano le domande di ricerca.

2. I claim di obiettività e accuratezza sono fuorvianti. Tutti i ricercatori interpretano i dati. Le scelte di design (cosa misurare, come pulire i dati, quali variabili includere) sono soggettive. I grandi dataset possono contenere errori sistematici che si amplificano con la combinazione di fonti diverse.

3. I Big Data non sono equivalenti ai Big Data. L'accesso ai dati non è democratico: grandi aziende e governi hanno accesso privilegiato che i ricercatori accademici non hanno. I dati disponibili dipendono da scelte commerciali e politiche, non dalla rilevanza scientifica.

4. I Big Data estrapolati dal contesto perdono significato. I dati social sono ampiamente usati per fare affermazioni sulle reti sociali, ma le relazioni rappresentate sui social media non equivalgono necessariamente alle reti personali studiate dai sociologi attraverso interviste e osservazioni.

Boyd e Crawford distinguono due tipi di reti sociali nei Big Data:

- **Reti articolate** (*articulated networks*): derivate da dichiarazioni esplicite degli utenti (liste di amici/follower). Includono amici intimi, conoscenti, colleghi, celebrity, ecc.
- **Reti comportamentali** (*behavioral networks*): derivate da pattern di comunicazione e interazione effettiva sulla piattaforma.

Entrambe hanno valore per i ricercatori, ma non sono equivalenti tra loro né alle reti personali reali. Ad esempio, la frequenza dei contatti non indica necessariamente la forza del legame, e non ogni connessione corrisponde a un'altra connessione.

5. Le questioni etiche sono complesse.

- **Consenso informato**: i dati social sono pubblici, ma non necessariamente ceduti per scopi di ricerca. Il fatto che un utente abbia pubblicato un contenuto su Facebook non significa che acconsenta al suo uso in una ricerca scientifica.
- **Anonimizzazione e re-identificazione**: dati apparentemente anonimi possono essere re-identificati combinando attributi. Un caso emblematico è lo studio di Lewis et al. (2008), in cui un gruppo di ricercatori di Harvard raccolse i profili Facebook di circa 1.700 studenti e li rese disponibili come dataset di ricerca. Il ricercatore Zimmer mostrò che la re-identificazione era possibile: includendo genere, stato di provenienza, corso di laurea ed etnia, i soggetti diventavano facilmente identificabili (es. l'unico studente albanese di un college privato del New England con circa 1.640 matricole). Gli autori dello studio risposero che i dati erano già presenti su Facebook, ma Zimmer controbatté che postare su Facebook non equivale a dare il consenso alla ricerca scientifica.
- **Discriminazione algoritmica**: modelli addestrati su dati storici possono perpetuare discriminazioni.

6. Accesso asimmetrico ai Big Data crea nuove disparità. La divisione tra chi ha e chi non ha accesso ai grandi dataset crea disuguaglianze nella produzione di conoscenza e nel potere decisionale.

Nota metodologica: correlazioni e causalità. Una limitazione trasversale all'analisi dei Big Data è che la correlazione statistica tra variabili non implica un nesso causale. I grandi dataset facilitano la scoperta di pattern ma non necessariamente la loro spiegazione causale. Occorre rigore metodologico per non trarre conclusioni errate.

Qualità dei dati sociali e tassonomia dei bias (Olteanu et al., 2019)

La raccolta e l'analisi dei dati social introduce sistematicamente dei bias che il ricercatore deve riconoscere e, per quanto possibile, controllare. Olteanu et al. (2019) propongono una tassonomia articolata in sei categorie:

1. **Population biases**: differenze demografiche tra gli utenti di una piattaforma e la popolazione target. Le principali piattaforme social presentano composizioni demografiche sistematicamente diverse dalla popolazione generale (es. divari per genere, età, etnia). Assumere che i dati siano rappresentativi della popolazione porta a conclusioni fuorvianti.

2. **Behavioral biases**: differenze nel comportamento degli utenti across piattaforme o contesti. Includono:

   - *Interaction biases*: come gli utenti interagiscono tra loro varia per relazione, demografia e funzionalità della piattaforma.
   - *Content consumption biases*: gli utenti tendono a consumare contenuti di persone simili, favorendo la formazione di *echo chambers*.
   - *Self-selection e misreport*: gli utenti pubblicano selettivamente (autocensura, rimozione contenuti) e possono dare auto-report inaccurati.

3. **Content production biases**: differenze lessicali, sintattiche e semantiche nei contenuti prodotti da popolazioni diverse. L'uso della lingua varia tra paesi, gruppi demografici e nel tempo; utenti "esperti" producono contenuti diversi da utenti normali.

4. **Linking biases**: differenze negli attributi delle reti costruite da connessioni o interazioni degli utenti. Le reti basate su connessioni esplicite (es. amici dichiarati) sono strutturalmente diverse da quelle basate su interazioni implicite (es. chi risponde a chi). L'omofilia può distorcere sistematicamente le percezioni degli utenti sulla prevalenza di certi attributi nella popolazione.

5. **Temporal variations**: variazioni nelle popolazioni, nei comportamenti e nelle piattaforme nel tempo. Includono fenomeni stagionali/periodici, eventi improvvisi (es. catastrofi naturali), cambiamenti di funzionalità della piattaforma, e il decadimento dei dataset nel tempo (cancellazione di account, restrizioni API).

6. **Functional biases**: bias derivanti dai meccanismi specifici delle piattaforme. Ogni piattaforma ha le proprie affordances (azioni incentivate o disincentivate) e algoritmi proprietari (spesso non documentati) che modellano il comportamento degli utenti e la distribuzione dei contenuti. Ad esempio, ridimensionare la

finestra di risposta su Facebook ha portato risposte più brevi, più frequenti e più rapide.

Ridondanza. Un ulteriore problema è la **ridondanza**: lo stesso contenuto può apparire in copie esatte (*duplicati*) o approssimate (*near-duplicates*), distorcendo la quantificazione dei fenomeni. La ridondanza può però essere anche un *segnale* (es. un messaggio ripubblicato molte volte indica viralità).

Attributi privati nei dati digitali

La ricerca di Kosinski et al. (2013) dimostrò che i *Facebook likes* permettono di prevedere con alta accuratezza attributi privati degli utenti (orientamento sessuale, etnia, opinioni politiche, tratti della personalità). Questo solleva questioni etiche fondamentali sull'uso dei dati digitali.

Capitolo A. Formulario riassuntivo

Misura	**Formula**	**Interpretazione**
Grado (non or.)	$k_i = \sum_j A_{ji}$	Numero di vicini
Grado medio	$\langle k \rangle = 2L/N$	Connettività media
Clustering loc.	$C_i = \frac{2L_i}{k_i(k_i-1)}$	Densità locale
Clustering medio	$\langle C \rangle = \frac{1}{N} \sum C_i$	Clustering globale
Betweenness	$C_B(i) = \sum_{s \neq i \neq t} \frac{\sigma_{st}(i)}{\sigma_{st}}$	Ruolo di intermediario
Closeness	$C_C(i) = \frac{N-1}{\sum_{j \neq i} d(i,j)}$	Efficienza di raggiungimento
Eigenvector	$\mathbf{Ax} = \lambda \mathbf{x}$	Importanza dei vicini
TF-IDF	$\text{TF} \times \log(\lvert D \rvert / \text{df})$	Rilevanza termine in doc

Capitolo B. Glossario

Arco (edge) Connessione tra due nodi in un grafo.

Betweenness centrality Misura di centralità basata su cammini più corti.

BERTopic Framework di topic modeling basato su BERT, UMAP e HDBSCAN.

BoW Bag of Words: rappresentazione vettoriale sparsa dei documenti.

Chiusura triadica Tendenza a formare triangoli in reti sociali.

Clustering coefficient Misura della densità di connessioni tra vicini.

Componente connessa Sottografo massimale in cui ogni coppia di nodi è raggiungibile.

Diametro Massima distanza geodesica in un grafo.

Grado (degree) Numero di archi incidenti su un nodo.

Grafo Struttura matematica composta da nodi e archi.

HDBSCAN Hierarchical Density-Based Spatial Clustering.

Homophily Tendenza a legarsi con chi è simile a noi.

igraph Libreria R/Python per analisi di reti.

Matrice di adiacenza Rappresentazione matriciale di un grafo.

Nodo (vertex) Elemento base di un grafo.

Omofilia Vedi Homophily.

Ponte locale Arco che collega nodi senza amici in comune.

Scale-free Rete con distribuzione di grado a power-law.

Sentiment analysis Analisi automatica della valenza emotiva dei testi.

Small world Rete con diametro piccolo e alto clustering.

TF-IDF Term Frequency–Inverse Document Frequency.

Topic modeling Scoperta automatica di temi latenti nei testi.

UMAP Uniform Manifold Approximation and Projection.